

# Redes Generativas Antagónicas

Antón Makarov Samusev

Universidad Complutense de Madrid

Universidad Politécnica de Madrid

11 de septiembre de 2019

- 1 Objetivos
- 2 Descripción del problema e historia
- 3 Métodos de punto interior
  - Algoritmo del elipsoide
  - Algoritmo primal
  - Algoritmo primal-dual
  - Algoritmo de Mehrotra
- 4 Complejidad
- 5 Conclusión
- 6 Referencias principales

- Historia de los métodos de punto interior.
- Descripción de los principales algoritmos.
- Descripción de algunas mejoras para los algoritmos de tipo primal-dual.
- Demostración de la complejidad.
- Implementación de algunos algoritmos en MATLAB.

# Descripción del problema

- Problema de programación lineal (PPL): maximizar o minimizar una función lineal sujeta a un conjunto de restricciones lineales.

# Descripción del problema

- Problema de programación lineal (PPL): maximizar o minimizar una función lineal sujeta a un conjunto de restricciones lineales.
- Forma primal estándar: mín  $c^T x$  sujeto a:  $Ax = b, x \geq 0$ , donde  $c, x \in \mathbb{R}^n, b \in \mathbb{R}^m$  y  $A \in \mathcal{M}_{m \times n}(\mathbb{R})$ .

# Descripción del problema

- Problema de programación lineal (PPL): maximizar o minimizar una función lineal sujeta a un conjunto de restricciones lineales.
- Forma primal estándar: mín  $c^T x$  sujeto a:  $Ax = b, x \geq 0$ , donde  $c, x \in \mathbb{R}^n, b \in \mathbb{R}^m$  y  $A \in \mathcal{M}_{m \times n}(\mathbb{R})$ .
- Forma dual: máx  $b^T y$  sujeto a:  $A^T y + s = c, s \geq 0$ , donde  $y \in \mathbb{R}^m$  y  $s \in \mathbb{R}^n$ .

# Descripción del problema

- Problema de programación lineal (PPL): maximizar o minimizar una función lineal sujeta a un conjunto de restricciones lineales.
- Forma primal estándar: mín  $c^T x$  sujeto a:  $Ax = b, x \geq 0$ , donde  $c, x \in \mathbb{R}^n, b \in \mathbb{R}^m$  y  $A \in \mathcal{M}_{m \times n}(\mathbb{R})$ .
- Forma dual: máx  $b^T y$  sujeto a:  $A^T y + s = c, s \geq 0$ , donde  $y \in \mathbb{R}^m$  y  $s \in \mathbb{R}^n$ .
- Condiciones KKT:

$$Ax = b$$

$$A^T y + s = c$$

$$XSe = 0$$

$$(x, s) \geq 0.$$

- Hasta 1979 → Algoritmo del símplex (Dantzig).



- Hasta 1979 → Algoritmo del símplex (Dantzig).
- 1979 → algoritmo del elipsoide (Khachiyan).

- Hasta 1979 → Algoritmo del símplex (Dantzig).
- 1979 → algoritmo del elipsoide (Khachiyan).
- 1984 → algoritmo proyectivo (Karmarkar).

- Hasta 1979 → Algoritmo del símplex (Dantzig).
- 1979 → algoritmo del elipsoide (Khachiyan).
- 1984 → algoritmo proyectivo (Karmarkar).
- 1985 → algoritmo primal de barrera logarítmica (Gill et. al.).

- Hasta 1979 → Algoritmo del símplex (Dantzig).
- 1979 → algoritmo del elipsoide (Khachiyan).
- 1984 → algoritmo proyectivo (Karmarkar).
- 1985 → algoritmo primal de barrera logarítmica (Gill et. al.).
- 1989 → algoritmo primal-dual (Megiddo).

- Hasta 1979 → Algoritmo del símplex (Dantzig).
- 1979 → algoritmo del elipsoide (Khachiyan).
- 1984 → algoritmo proyectivo (Karmarkar).
- 1985 → algoritmo primal de barrera logarítmica (Gill et. al.).
- 1989 → algoritmo primal-dual (Megiddo).
- 1992 → algoritmo primal-dual predictor-corrector (Mehrotra).

# Algoritmo del elipsoide (Factibilidad)

Fórmulas de actualización del elipsoide ( $d$  es la fila de  $A$  correspondiente a la restricción que no se cumple).

$$x^{k+1} = x^k - \frac{1}{n+1} \frac{D_k d}{\sqrt{d^T D_k d}}, \quad (1)$$

$$D_{k+1} = \frac{n^2}{n^2 - 1} \left( D_k - \frac{2}{n+1} \frac{(D_k d)(D_k d)^T}{d^T D_k d} \right). \quad (2)$$

- Dado un punto inicial  $x^0 \in \mathbb{R}^n$ . Tomamos un elipsoide centrado en él que contenga al conjunto estrictamente factible  $\hat{P}$ .

# Algoritmo del elipsoide (Factibilidad)

Fórmulas de actualización del elipsoide ( $d$  es la fila de  $A$  correspondiente a la restricción que no se cumple).

$$x^{k+1} = x^k - \frac{1}{n+1} \frac{D_k d}{\sqrt{d^T D_k d}}, \quad (1)$$

$$D_{k+1} = \frac{n^2}{n^2 - 1} \left( D_k - \frac{2}{n+1} \frac{(D_k d)(D_k d)^T}{d^T D_k d} \right). \quad (2)$$

- Dado un punto inicial  $x^0 \in \mathbb{R}^n$ . Tomamos un elipsoide centrado en él que contenga al conjunto estrictamente factible  $\hat{P}$ .
- El algoritmo comprueba si el punto es o no factible. Si lo es, termina.

# Algoritmo del elipsoide (Factibilidad)

Fórmulas de actualización del elipsoide ( $d$  es la fila de  $A$  correspondiente a la restricción que no se cumple).

$$x^{k+1} = x^k - \frac{1}{n+1} \frac{D_k d}{\sqrt{d^T D_k d}}, \quad (1)$$

$$D_{k+1} = \frac{n^2}{n^2 - 1} \left( D_k - \frac{2}{n+1} \frac{(D_k d)(D_k d)^T}{d^T D_k d} \right). \quad (2)$$

- Dado un punto inicial  $x^0 \in \mathbb{R}^n$ . Tomamos un elipsoide centrado en él que contenga al conjunto estrictamente factible  $\hat{P}$ .
- El algoritmo comprueba si el punto es o no factible. Si lo es, termina.
- Si no es factible, busca cuál es la inecuación que no se cumple y toma como  $d$  la fila de  $A$  correspondiente.



# Algoritmo del elipsoide (Factibilidad)

Fórmulas de actualización del elipsoide ( $d$  es la fila de  $A$  correspondiente a la restricción que no se cumple).

$$x^{k+1} = x^k - \frac{1}{n+1} \frac{D_k d}{\sqrt{d^T D_k d}}, \quad (1)$$

$$D_{k+1} = \frac{n^2}{n^2 - 1} \left( D_k - \frac{2}{n+1} \frac{(D_k d)(D_k d)^T}{d^T D_k d} \right). \quad (2)$$

- Dado un punto inicial  $x^0 \in \mathbb{R}^n$ . Tomamos un elipsoide centrado en él que contenga al conjunto estrictamente factible  $\hat{P}$ .
- El algoritmo comprueba si el punto es o no factible. Si lo es, termina.
- Si no es factible, busca cuál es la inecuación que no se cumple y toma como  $d$  la fila de  $A$  correspondiente.
- Se actualiza el elipsoide mediante las fórmulas (1) y (2).

# Algoritmo del elipsoide (Factibilidad)

Fórmulas de actualización del elipsoide ( $d$  es la fila de  $A$  correspondiente a la restricción que no se cumple).

$$x^{k+1} = x^k - \frac{1}{n+1} \frac{D_k d}{\sqrt{d^T D_k d}}, \quad (1)$$

$$D_{k+1} = \frac{n^2}{n^2 - 1} \left( D_k - \frac{2}{n+1} \frac{(D_k d)(D_k d)^T}{d^T D_k d} \right). \quad (2)$$

- Dado un punto inicial  $x^0 \in \mathbb{R}^n$ . Tomamos un elipsoide centrado en él que contenga al conjunto estrictamente factible  $\hat{P}$ .
- El algoritmo comprueba si el punto es o no factible. Si lo es, termina.
- Si no es factible, busca cuál es la inecuación que no se cumple y toma como  $d$  la fila de  $A$  correspondiente.
- Se actualiza el elipsoide mediante las fórmulas (1) y (2).
- El proceso se repite hasta que se encuentra un punto factible o hasta que se alcanza el máximo número de iteraciones, en cuyo caso se concluye que  $\hat{P} = \emptyset$ .

# Algoritmo del elipsoide (Optimización)

Queremos resolver el problema de programación lineal descrito por:

$$z = \max\{c^T x : x \in P\}, \quad P = \{x \in \mathbb{R}^n : Ax \leq b\}.$$

Podemos aplicar el algoritmo de factibilidad de manera iterada.

Cada vez que lleguemos a un punto factible, vamos a añadir al sistema  $(A|b)$  una fila que proporcione una restricción con la misma forma de la función objetivo y que pase por dicho punto, reduciendo cada vez más el conjunto factible y por tanto la zona donde se busca el óptimo.

Ejemplo:

$$\begin{aligned} & \max x_1 + x_2 \\ \text{sujeto a: } & -x_1 + 3x_2 \leq 3 \\ & 2x_1 + x_2 \leq 8 \\ & -6x_1 + x_2 \leq -4 \\ & x_1, x_2 \geq 0. \end{aligned} \tag{3}$$

# Ejemplo de aplicación (factibilidad)

# Ejemplo de aplicación (Optimización)

# Algoritmo primal

- Función de barrera logarítmica:  $B(x, \mu) = c^T x - \mu \sum_{i=1}^n \log x_i$ .

# Algoritmo primal

- Función de barrera logarítmica:  $B(x, \mu) = c^T x - \mu \sum_{i=1}^n \log x_i$ .
- Problema a resolver: mín  $B(x, \mu)$  sujeto a:  $Ax = b$ .

# Algoritmo primal

- Función de barrera logarítmica:  $B(x, \mu) = c^T x - \mu \sum_{i=1}^n \log x_i$ .
- Problema a resolver: mín  $B(x, \mu)$  sujeto a:  $Ax = b$ .
- Condiciones KKT:

$$Ax = b$$

$$A^T y + s = c$$

$$XSe = \mu e$$

$$(x, s) \geq 0.$$



# Algoritmo primal

- Función de barrera logarítmica:  $B(x, \mu) = c^T x - \mu \sum_{i=1}^n \log x_i$ .
- Problema a resolver: mín  $B(x, \mu)$  sujeto a:  $Ax = b$ .
- Condiciones KKT:

$$Ax = b$$

$$A^T y + s = c$$

$$XSe = \mu e$$

$$(x, s) \geq 0.$$

- Formulación:

$$\begin{pmatrix} H & A^T \\ A & 0 \end{pmatrix} \begin{pmatrix} -\Delta x \\ y \end{pmatrix} = \begin{pmatrix} c - \mu X^{-1} e \\ 0 \end{pmatrix}.$$

# Algoritmo primal

- Función de barrera logarítmica:  $B(x, \mu) = c^T x - \mu \sum_{i=1}^n \log x_i$ .
- Problema a resolver: mín  $B(x, \mu)$  sujeto a:  $Ax = b$ .
- Condiciones KKT:

$$Ax = b$$

$$A^T y + s = c$$

$$XSe = \mu e$$

$$(x, s) \geq 0.$$

- Formulación:

$$\begin{pmatrix} H & A^T \\ A & 0 \end{pmatrix} \begin{pmatrix} -\Delta x \\ y \end{pmatrix} = \begin{pmatrix} c - \mu X^{-1}e \\ 0 \end{pmatrix}.$$

- Parámetros:
  - centralización  $\sigma \rightarrow \mu_{k+1} = \sigma \mu_k$ .
  - moderación  $\alpha \rightarrow x^{k+1} = x^k + \alpha \Delta x^k$ .

# Algoritmo primal

- Función de barrera logarítmica:  $B(x, \mu) = c^T x - \mu \sum_{i=1}^n \log x_i$ .
- Problema a resolver: mín  $B(x, \mu)$  sujeto a:  $Ax = b$ .
- Condiciones KKT:

$$Ax = b$$

$$A^T y + s = c$$

$$XSe = \mu e$$

$$(x, s) \geq 0.$$

- Formulación:

$$\begin{pmatrix} H & A^T \\ A & 0 \end{pmatrix} \begin{pmatrix} -\Delta x \\ y \end{pmatrix} = \begin{pmatrix} c - \mu X^{-1}e \\ 0 \end{pmatrix}.$$

- Parámetros:
  - centralización  $\sigma \rightarrow \mu_{k+1} = \sigma \mu_k$ .
  - moderación  $\alpha \rightarrow x^{k+1} = x^k + \alpha \Delta x^k$ .
- Criterio de parada  $\rightarrow$  cuando  $\|\Delta x^k\|$  sea suficientemente pequeño.

- Aprovecha la información del problema dual.

- Aprovecha la información del problema dual.
- Formulación:

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} \Delta x \\ \Delta y \\ \Delta s \end{pmatrix} = \begin{pmatrix} -(A^T y + s - c) \\ -(Ax - b) \\ -XSe + \sigma \mu e \end{pmatrix}.$$

- Aprovecha la información del problema dual.
- Formulación:

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} \Delta x \\ \Delta y \\ \Delta s \end{pmatrix} = \begin{pmatrix} -(A^T y + s - c) \\ -(Ax - b) \\ -XSe + \sigma \mu e \end{pmatrix}.$$

- Precisa de los mismos parámetros que el algoritmo primal.

- Aprovecha la información del problema dual.
- Formulación:

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} \Delta x \\ \Delta y \\ \Delta s \end{pmatrix} = \begin{pmatrix} -(A^T y + s - c) \\ -(Ax - b) \\ -XSe + \sigma \mu e \end{pmatrix}.$$

- Precisa de los mismos parámetros que el algoritmo primal.
- Criterio de parada  $\rightarrow$  cuando  $\mu = x^T s / n$  sea suficientemente pequeño. A este valor se le llama medida de dualidad.

¿Qué buscamos?

- $x^0, s^0 > 0$ .
- Norma pequeña.
- Componentes no muy distintas y no demasiado cercanas a cero.



## Punto inicial II

¿Cómo lo hacemos?

- Calculamos el vector  $\tilde{x}$  de norma mínima que satisfaga la restricción primal y el vector  $(\tilde{y}, \tilde{s})$  que satisfaga la restricción dual con  $s$  de norma mínima.

## Punto inicial II

¿Cómo lo hacemos?

- Calculamos el vector  $\tilde{x}$  de norma mínima que satisfaga la restricción primal y el vector  $(\tilde{y}, \tilde{s})$  que satisfaga la restricción dual con  $s$  de norma mínima.
- En general  $\tilde{x}$  y  $\tilde{s}$  pueden tener componentes negativas. Lo evitamos definiendo los parámetros

$$\delta_x = \max(- (3/2) \min_i \tilde{x}_i, 0), \quad \delta_s = \max(- (3/2) \min_i \tilde{s}_i, 0).$$

Hacemos  $\hat{x} = \tilde{x} + \delta_x e$ ,  $\hat{s} = \tilde{s} + \delta_s e$ .

## Punto inicial II

¿Cómo lo hacemos?

- Calculamos el vector  $\tilde{x}$  de norma mínima que satisfaga la restricción primal y el vector  $(\tilde{y}, \tilde{s})$  que satisfaga la restricción dual con  $s$  de norma mínima.
- En general  $\tilde{x}$  y  $\tilde{s}$  pueden tener componentes negativas. Lo evitamos definiendo los parámetros

$$\delta_x = \max(-\frac{3}{2} \min_i \tilde{x}_i, 0), \quad \delta_s = \max(-\frac{3}{2} \min_i \tilde{s}_i, 0).$$

Hacemos  $\hat{x} = \tilde{x} + \delta_x e$ ,  $\hat{s} = \tilde{s} + \delta_s e$ .

- Para que las componentes de  $x^0$  y  $s^0$  no sean demasiado distintas ni cercanas a cero, definimos dos parámetros más:

$$\hat{\delta}_x = \frac{1}{2} \frac{\hat{x}^T \hat{s}}{e^T \hat{s}}, \quad \hat{\delta}_s = \frac{1}{2} \frac{\hat{x}^T \hat{s}}{e^T \hat{x}}.$$

## Punto inicial II

¿Cómo lo hacemos?

- Calculamos el vector  $\tilde{x}$  de norma mínima que satisfaga la restricción primal y el vector  $(\tilde{y}, \tilde{s})$  que satisfaga la restricción dual con  $s$  de norma mínima.
- En general  $\tilde{x}$  y  $\tilde{s}$  pueden tener componentes negativas. Lo evitamos definiendo los parámetros

$$\delta_x = \max(-\frac{3}{2} \min_i \tilde{x}_i, 0), \quad \delta_s = \max(-\frac{3}{2} \min_i \tilde{s}_i, 0).$$

Hacemos  $\hat{x} = \tilde{x} + \delta_x e$ ,  $\hat{s} = \tilde{s} + \delta_s e$ .

- Para que las componentes de  $x^0$  y  $s^0$  no sean demasiado distintas ni cercanas a cero, definimos dos parámetros más:

$$\hat{\delta}_x = \frac{1}{2} \frac{\hat{x}^T \hat{s}}{e^T \hat{s}}, \quad \hat{\delta}_s = \frac{1}{2} \frac{\hat{x}^T \hat{s}}{e^T \hat{x}}.$$

- El punto inicial será:

$$x^0 = \hat{x} + \hat{\delta}_x e, \quad y^0 = \tilde{y}, \quad s^0 = \hat{s} + \hat{\delta}_s e.$$

- Obtener el paso afín o de predicción:

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} \Delta x^{\text{af}} \\ \Delta y^{\text{af}} \\ \Delta s^{\text{af}} \end{pmatrix} = \begin{pmatrix} -(A^T y + s - c) \\ -(Ax - b) \\ -XSe \end{pmatrix}.$$

- Obtener el paso afín o de predicción:

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} \Delta x^{\text{af}} \\ \Delta y^{\text{af}} \\ \Delta s^{\text{af}} \end{pmatrix} = \begin{pmatrix} -(A^T y + s - c) \\ -(Ax - b) \\ -XS e \end{pmatrix}.$$

- Utilizando el paso afín, obtener el paso de corrección:

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} \Delta x^{\text{corr}} \\ \Delta y^{\text{corr}} \\ \Delta s^{\text{corr}} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ -\Delta x^{\text{af}} \Delta S^{\text{af}} e \end{pmatrix}.$$

- Obtener el paso afín o de predicción:

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} \Delta x^{\text{af}} \\ \Delta y^{\text{af}} \\ \Delta s^{\text{af}} \end{pmatrix} = \begin{pmatrix} -(A^T y + s - c) \\ -(Ax - b) \\ -XSe \end{pmatrix}.$$

- Utilizando el paso afín, obtener el paso de corrección:

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} \Delta x^{\text{corr}} \\ \Delta y^{\text{corr}} \\ \Delta s^{\text{corr}} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ -\Delta x^{\text{af}} \Delta S^{\text{af}} e \end{pmatrix}.$$

- Combinar ambos pasos:

$$(\Delta x^{\text{af}}, \Delta y^{\text{af}}, \Delta s^{\text{af}}) + (\Delta x^{\text{corr}}, \Delta y^{\text{corr}}, \Delta s^{\text{corr}}).$$

- Heurística: elegir  $\sigma_k$  apropiado en cada iteración.



# Parámetro de centralización

- Heurística: elegir  $\sigma_k$  apropiado en cada iteración.
- Si el paso de escalado aún reduce de manera significativa la medida de dualidad, podemos tomar un valor pequeño de  $\sigma_k$ .

- Heurística: elegir  $\sigma_k$  apropiado en cada iteración.
- Si el paso de escalado aún reduce de manera significativa la medida de dualidad, podemos tomar un valor pequeño de  $\sigma_k$ .
- Si no se puede hacer un paso grande sobre la dirección, tomamos un valor de  $\sigma_k$  grande, con el objetivo de centrar la iteración siguiente.

- Heurística: elegir  $\sigma_k$  apropiado en cada iteración.
- Si el paso de escalado afín reduce de manera significativa la medida de dualidad, podemos tomar un valor pequeño de  $\sigma_k$ .
- Si no se puede hacer un paso grande sobre la dirección, tomamos un valor de  $\sigma_k$  grande, con el objetivo de centrar la iteración siguiente.
- Para ello hacemos:

$$\mu_{\text{af}} = \frac{(x + \alpha_{\text{af}}^{\text{primal}} \Delta x)^T (s + \alpha_{\text{af}}^{\text{dual}} \Delta s)}{n}, \quad \sigma = \left( \frac{\mu_{\text{af}}}{\mu} \right)^3.$$

- Se calculan por separado las longitudes de paso más grandes posibles tales que las variables  $x$  y  $s$  se mantengan no negativas.

$$\alpha_{k,\max}^{\text{primal}} = \min_{i:\Delta x_i^k < 0} -\frac{x_i^k}{\Delta x_i^k}, \quad \alpha_{k,\max}^{\text{dual}} = \min_{i:\Delta s_i^k < 0} -\frac{s_i^k}{\Delta s_i^k}.$$

- Se calculan por separado las longitudes de paso más grandes posibles tales que las variables  $x$  y  $s$  se mantengan no negativas.

$$\alpha_{k,\max}^{\text{primal}} = \min_{i: \Delta x_i^k < 0} -\frac{x_i^k}{\Delta x_i^k}, \quad \alpha_{k,\max}^{\text{dual}} = \min_{i: \Delta s_i^k < 0} -\frac{s_i^k}{\Delta s_i^k}.$$

- Mejor utilizar pasos grandes  $\rightarrow$  se toma un parámetro  $\eta \in [0, 1)$ :

$$\alpha_k^{\text{primal}} = \min(1, \eta \alpha_{k,\max}^{\text{primal}}), \quad \alpha_k^{\text{dual}} = \min(1, \eta \alpha_{k,\max}^{\text{dual}}).$$

## Pregunta

¿Cuál es el número de iteraciones necesario para alcanzar una brecha de dualidad  $\leq \psi$ ?

Sea  $\epsilon = \frac{\psi}{\mu_0}$ , donde  $\mu_0 = \frac{\sum_i x_i^0 s_i^0}{n}$ .

Sea  $K$  el mínimo valor de  $k = 1, 2, \dots$  tal que  $\mu_k \leq \psi$ . Se tiene que:

$$K = \frac{n}{\delta} \log \left( \frac{1}{\epsilon} \right).$$

Como  $\delta$  no depende de  $n$ , el número de iteraciones necesarias es:

$$\mathcal{O} \left( n \log \left( \frac{1}{\epsilon} \right) \right).$$

Además, en cada iteración las operaciones tienen complejidad polinomial. Por tanto, el algoritmo tiene complejidad polinomial.

# Rendimiento I

Problema (3) puesto en forma estándar:

$$\begin{aligned} & \text{mín } -x_1 - x_2 \\ \text{sujeto a: } & -x_1 + 3x_2 + h_1 = 3 \\ & 2x_1 + x_2 + h_2 = 8 \\ & -6x_1 + x_2 + h_3 = -4 \\ & x_1, x_2, h_1, h_2, h_3 \geq 0. \end{aligned}$$

Método	Óptimo - Resultado	Iteraciones	$\mu$
Elipsoide	0.1402	12	-
Mehrotra	0	7	$1,1661 \times 10^{-7}$
EJOR	0	19	$1,9073 \times 10^{-6}$

## Importante

Con estos resultados no queremos decir que un algoritmo sea mejor que otro, no obstante, es satisfactorio comprobar que se corresponden con lo previsto.

# Rendimiento II

Comparativa del número de iteraciones necesarias para alcanzar distintas precisiones con el algoritmo de Mehrotra.

Valor de $\mu$ pedido	Valor de $\mu$ alcanzado	Número de iteraciones
$1 \times 10^{-1}$	0,0344	2
$1 \times 10^{-2}$	0,0029	3
$1 \times 10^{-3}$	$2,2781 \times 10^{-4}$	4
$1 \times 10^{-4}$	$1,8221 \times 10^{-5}$	5
$1 \times 10^{-5}$	$1,4577 \times 10^{-6}$	6
$1 \times 10^{-6}$	$1,1661 \times 10^{-7}$	7
$1 \times 10^{-9}$	$7,4633 \times 10^{-10}$	9
$1 \times 10^{-12}$	$3,8212 \times 10^{-13}$	12





- Los métodos de punto interior son una herramienta muy potente para resolver problemas de programación lineal.
- Son muy eficientes al ser aplicados a problemas reales de gran tamaño.
- Aseguran que resolveremos nuestros problemas de optimización en  $\mathcal{O}(n \log(1/\epsilon))$  iteraciones.
- La implementación de los algoritmos ha sido una parte fundamental en el aprendizaje.
- La demostración de la complejidad ha revelado técnicas interesantes.

# Referencias principales



Gondzio, J. *Interior point methods 25 years later*. European Journal of Operational Research 218, 587–601, 2012.



Nemhauser G. L., Wolsey, L. A. *Integer and Combinatorial Optimization*. Wiley Interscience Series in Discrete Mathematics and Optimization, New York, 1988.



Nocedal, J., Wright, S. J. *Numerical Optimization*. Springer, 2006.



Robere, R. *Interior Point Methods and Linear Programming*. University of Toronto, 2012.

Gracias por su atención.

¿Preguntas?