

Redes Generativas Antagónicas

Antón Makarov Samusev

Universidad Complutense de Madrid

Universidad Politécnica de Madrid

amakarov@ucm.es

25 de septiembre de 2019

1 Redes Generativas Antagónicas

2 Generación de arte

- DCGAN
- Metodología
- Resultados
- Recursos y rendimiento

3 Algunas arquitecturas basadas en GANs

4 Consideraciones prácticas

5 Conclusión

6 Referencias principales

Descripción del problema

- Goodfellow et. al. 2014

Descripción del problema

- Goodfellow et. al. 2014
- Aprendizaje no supervisado

Descripción del problema

- Goodfellow et. al. 2014
- Aprendizaje no supervisado
- Describir la distribución que siguen los datos

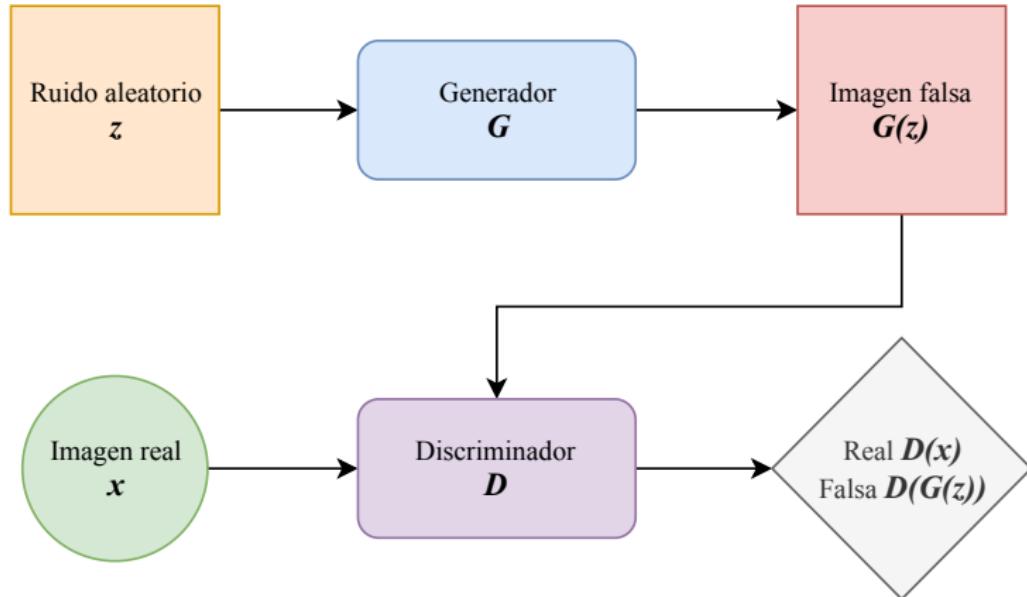
Descripción del problema

- Goodfellow et. al. 2014
- Aprendizaje no supervisado
- Describir la distribución que siguen los datos
- Generar muestras a partir de dicha distribución

Descripción del problema

- Goodfellow et. al. 2014
- Aprendizaje no supervisado
- Describir la distribución que siguen los datos
- Generar muestras a partir de dicha distribución
- Mediante redes neuronales que compiten entre sí

Idea conceptual



Aspectos teóricos

$$\min_G \max_D V(G, D) = \mathbb{E}_{x \sim p_d(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))].$$

Deep Convolutional Generative Adversarial Network

- Discriminador: Convolución con stride
- Generador: Convolución fraccional con stride
- No utilizar capas totalmente conectadas
- Generador: ReLU + tanh
- Discriminador: LeakyReLU + sigmoide
- BatchNorm
- Inicialización gaussiana

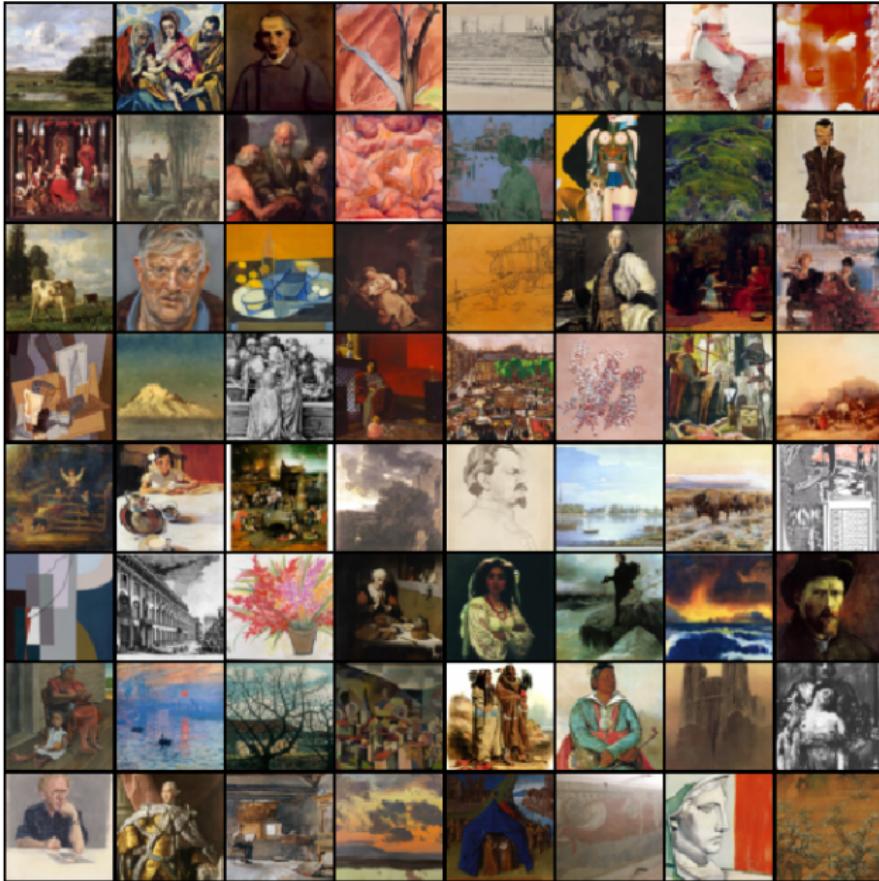
Deep Convolutional Generative Adversarial Network

- Discriminador: Convolución con stride
- Generador: Convolución fraccional con stride
- No utilizar capas totalmente conectadas
- Generador: ReLU + tanh
- Discriminador: LeakyReLU + sigmoide
- BatchNorm
- Inicialización gaussiana
- One sided label smoothing

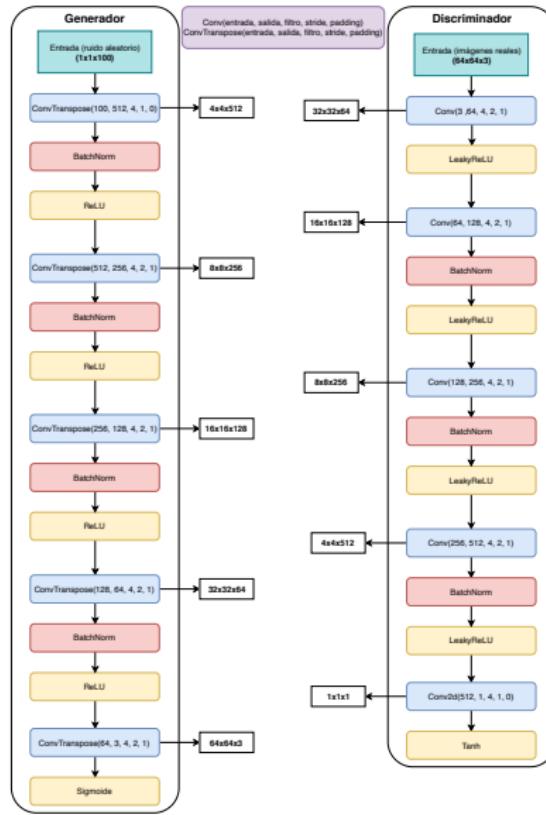
Obtención y pre-procesado

- Conjunto de datos obtenido de una competición de Kaggle
- Más de 100000 imágenes \approx 50 GB
- Algunas imágenes corruptas
- Escalado de tamaños y proporciones
- Normalización
- Carga como tensores

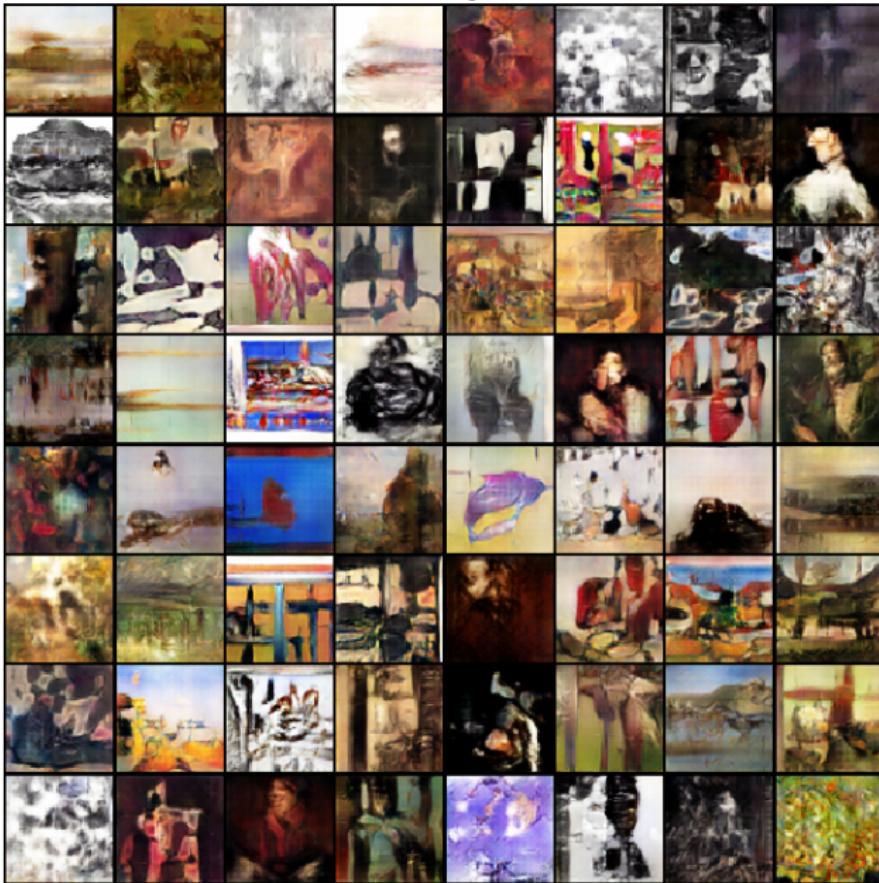
Real Images

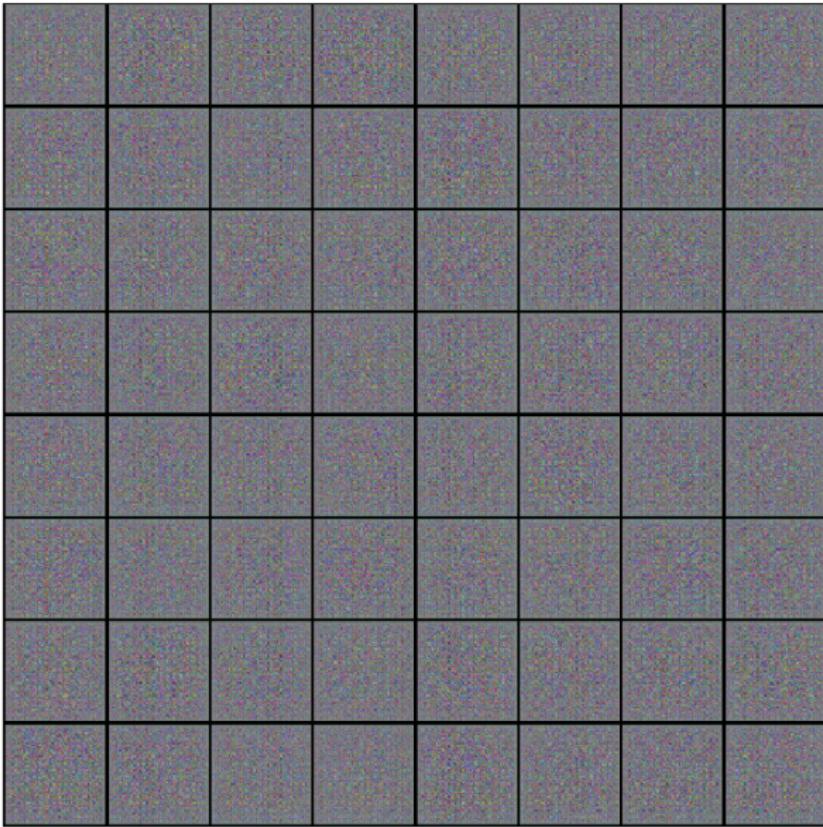


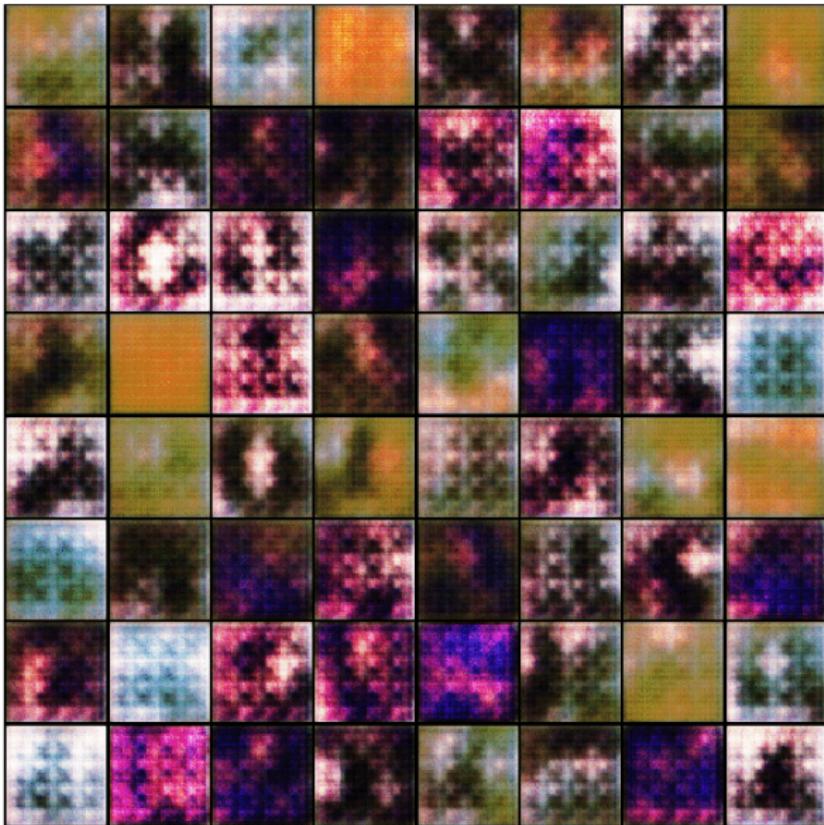
Arquitectura

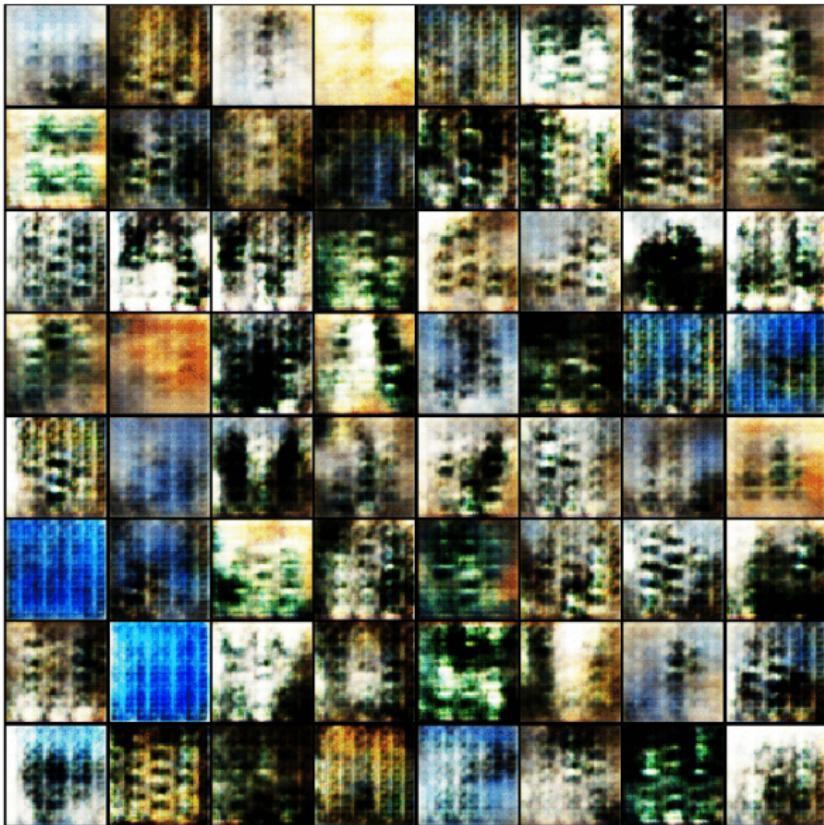


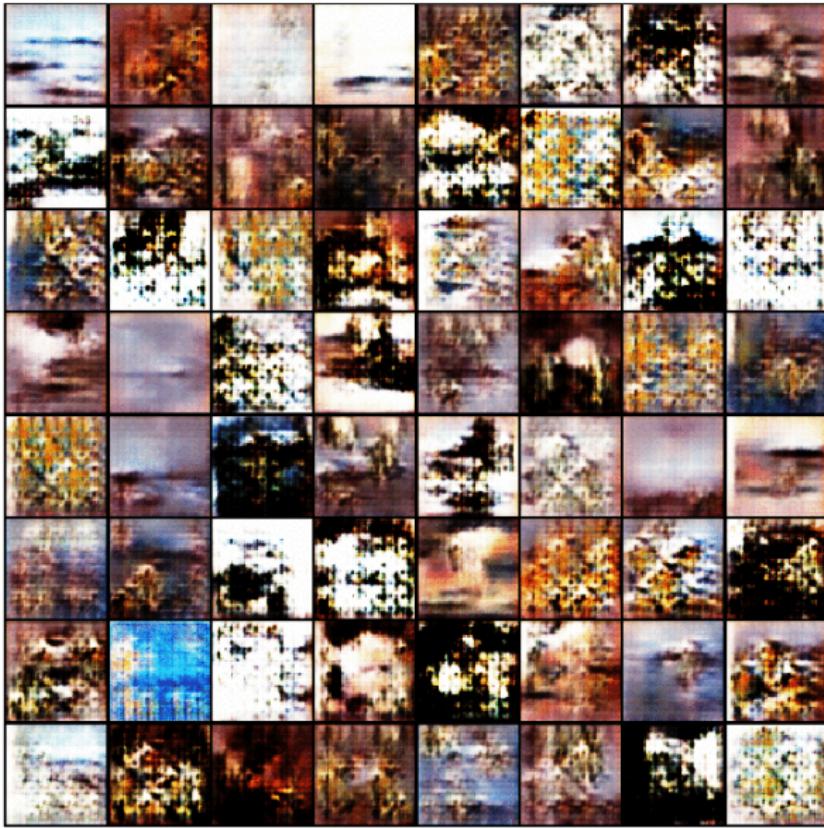
Fake Images

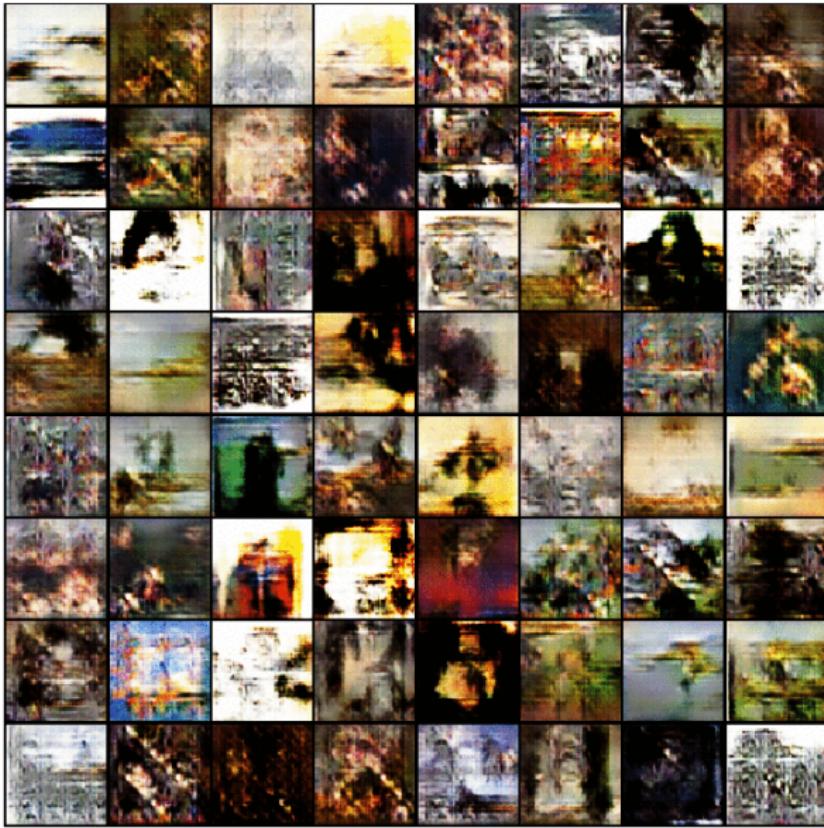


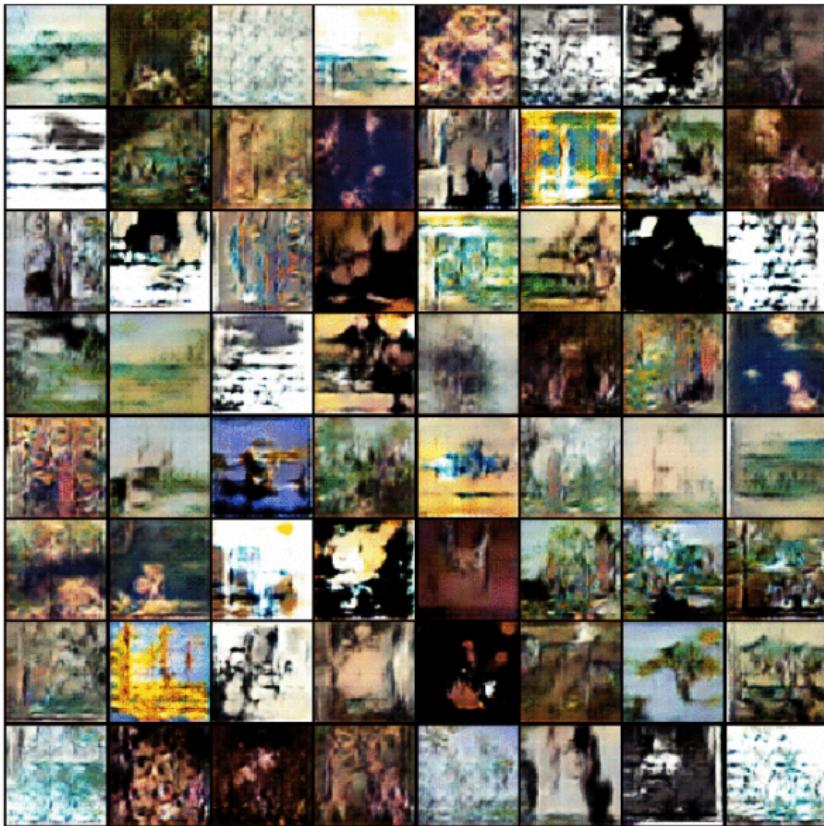




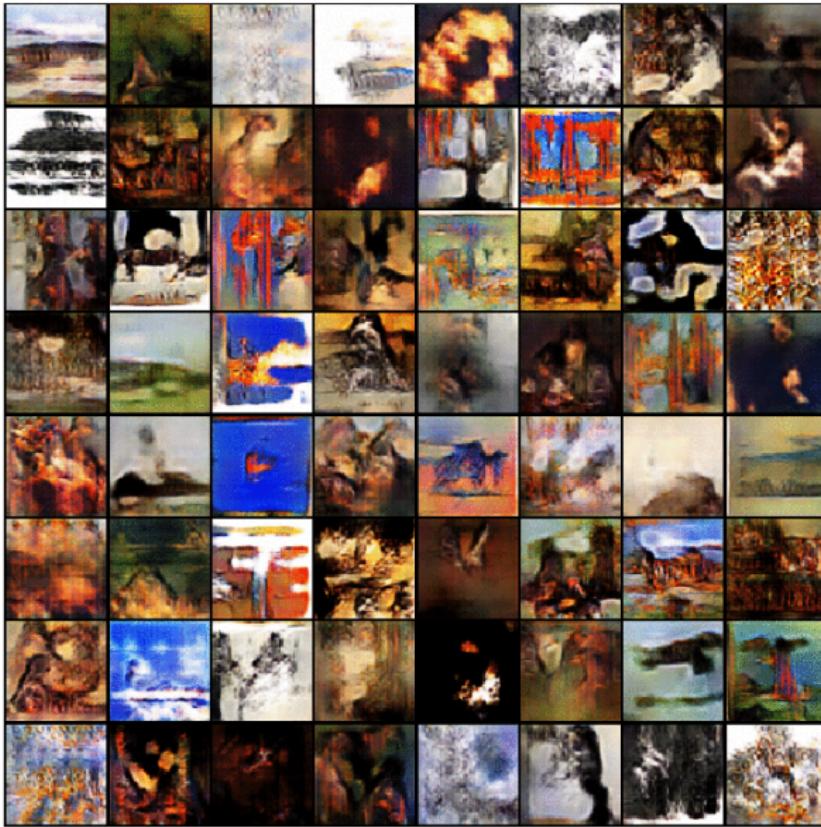


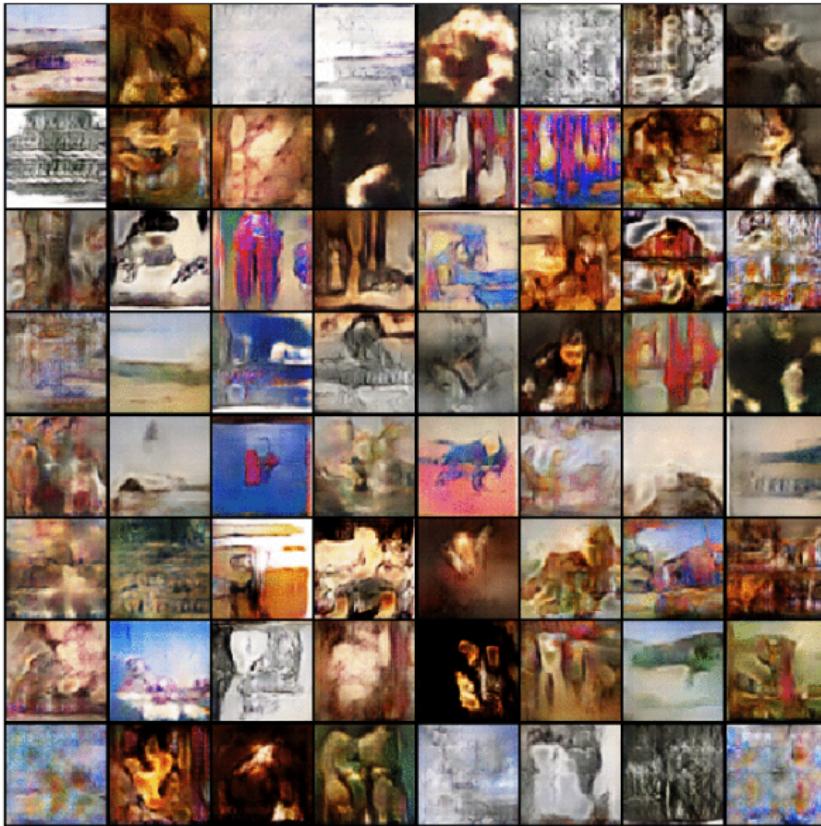


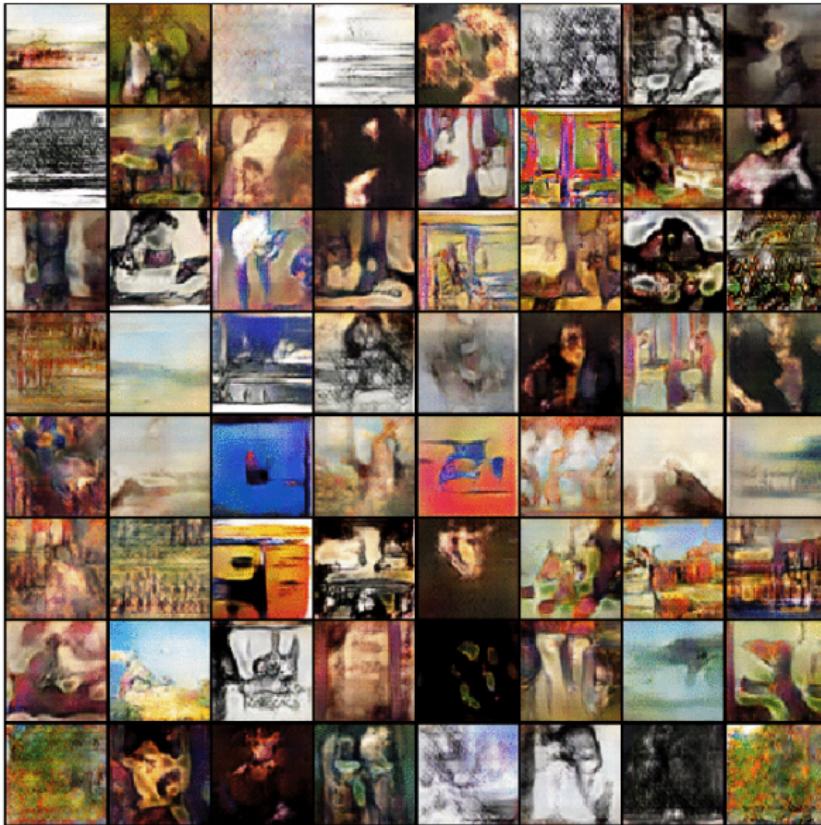


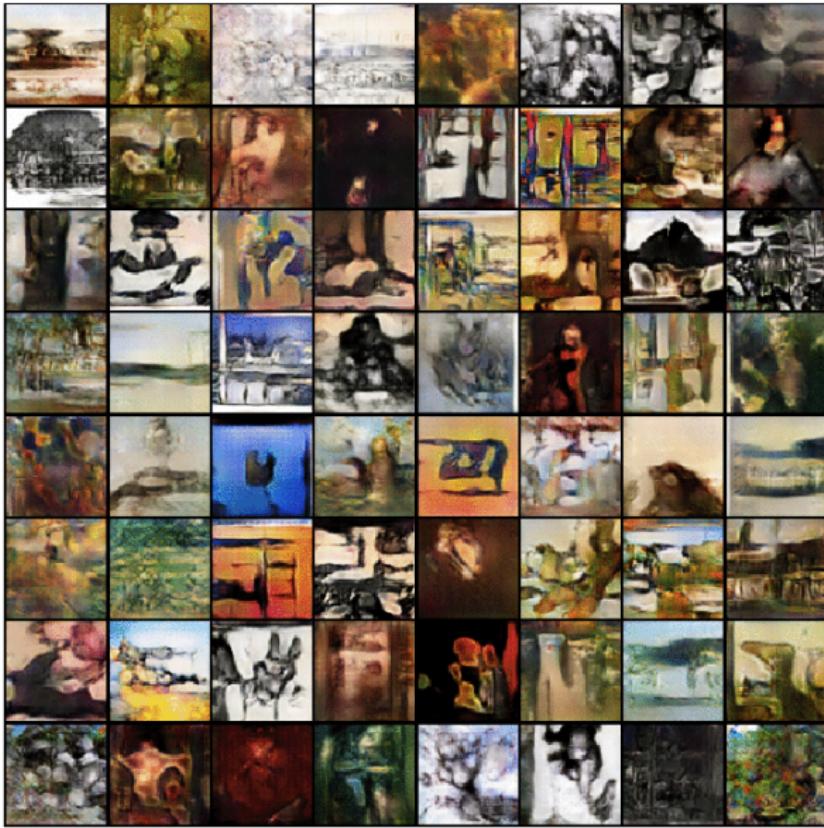


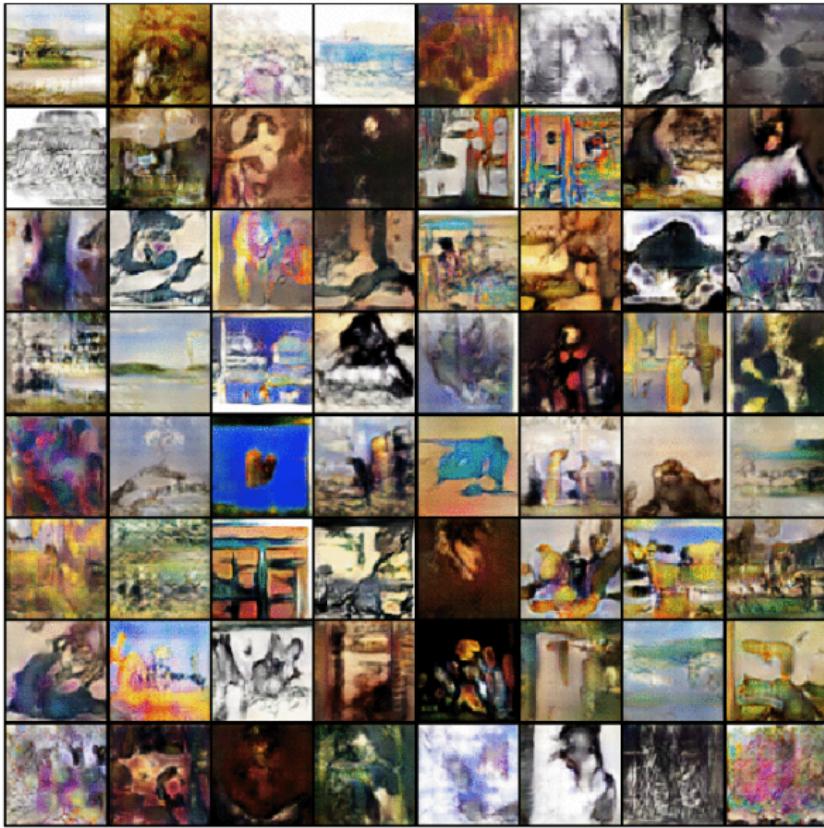


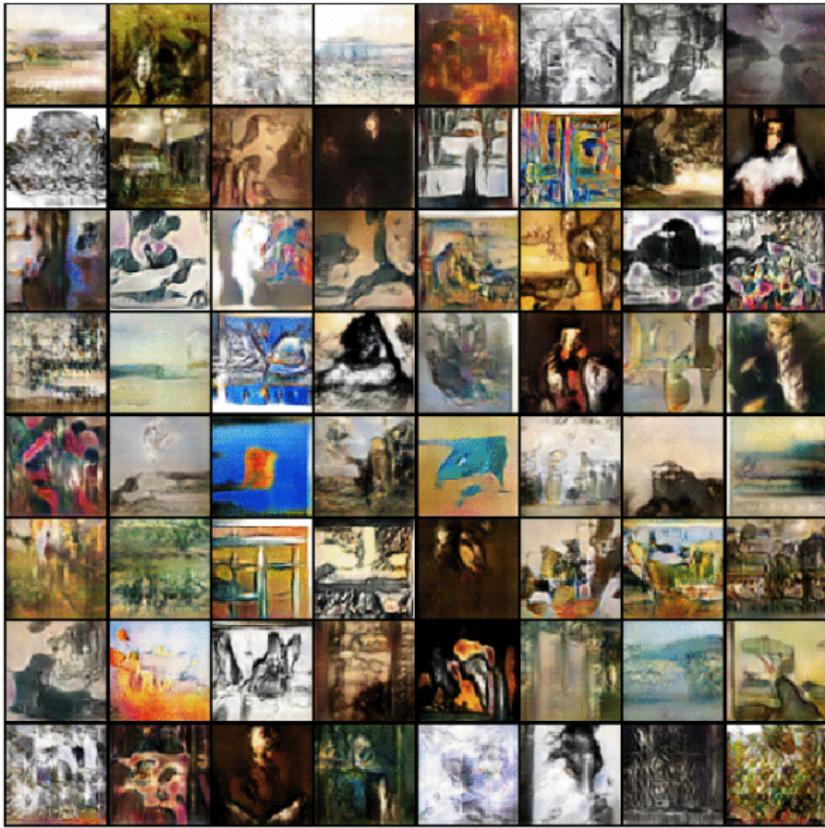


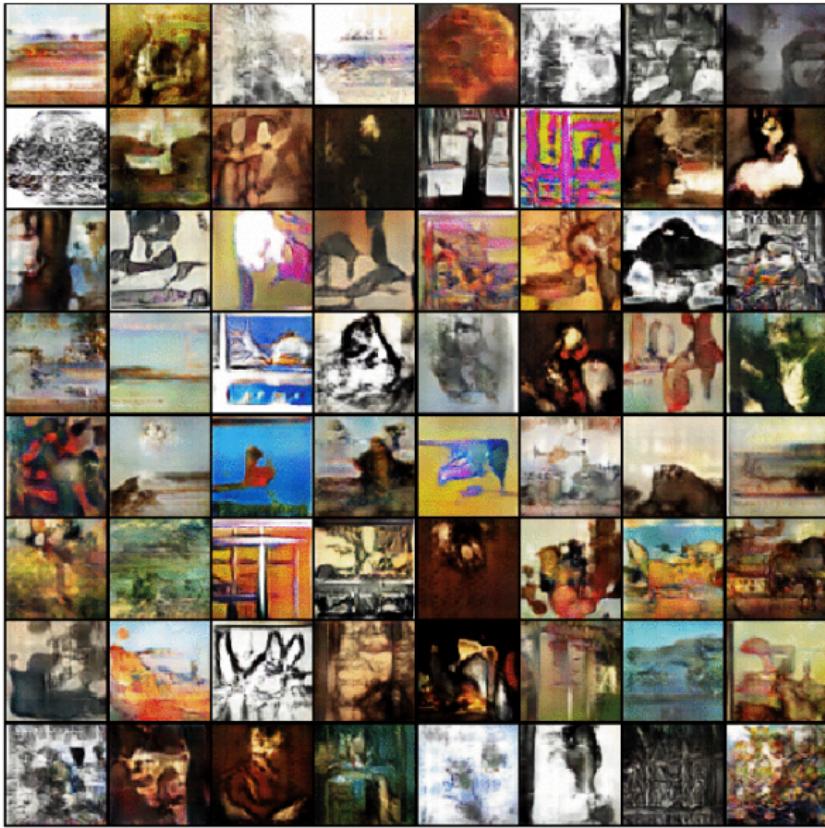


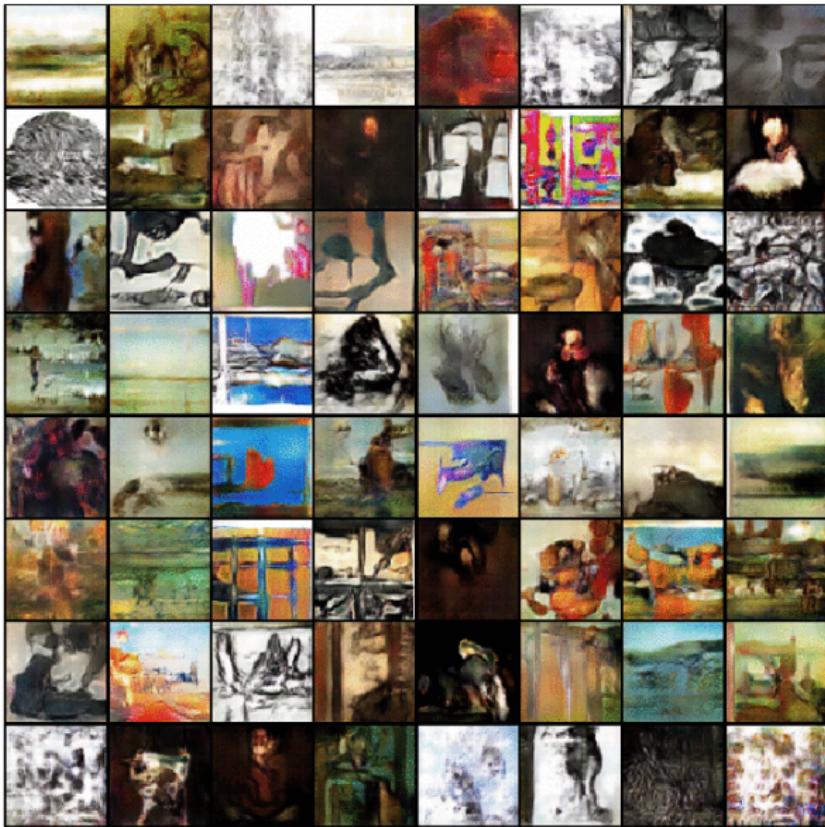


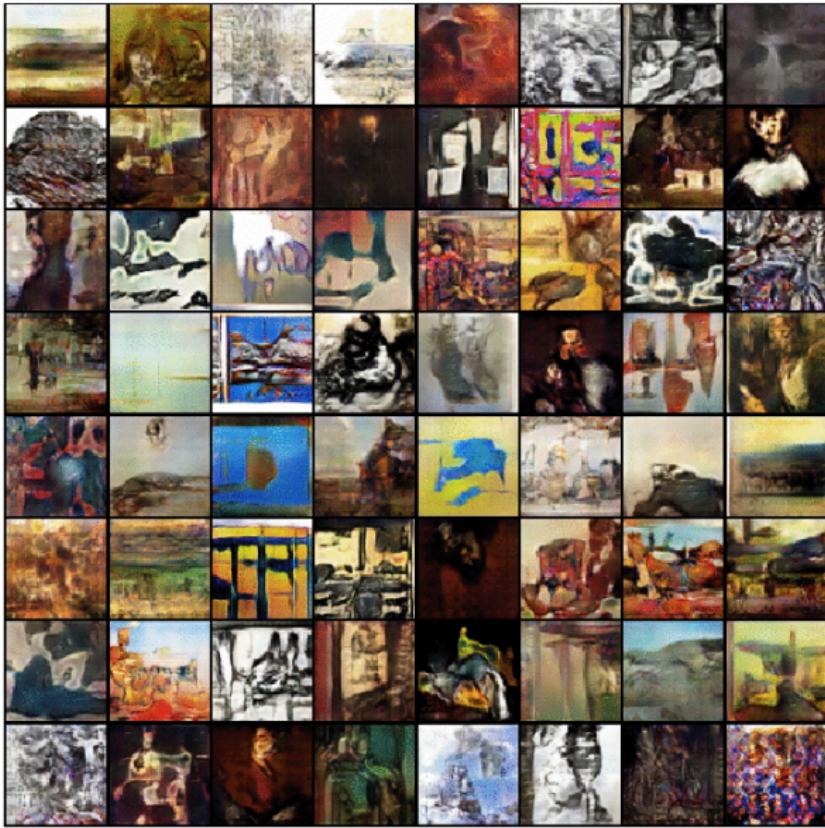


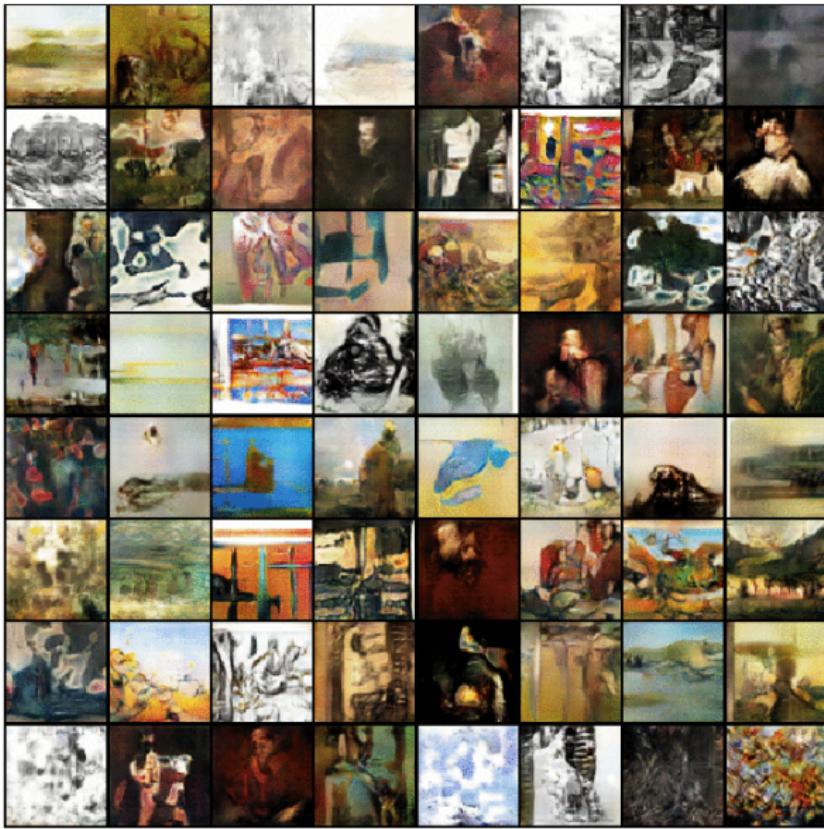












Recursos y rendimiento

- Imprescindible GPU para el entrenamiento
- 24 horas para 30 épocas
- en PC normal, 20 veces más lento

Evolución en generación de caras



Figura: Ian Goodfellow. 4.5 years of GAN progress on face generation.

DCGAN



man
with glasses



man
without glasses



woman
without glasses



woman with glasses

Text to image

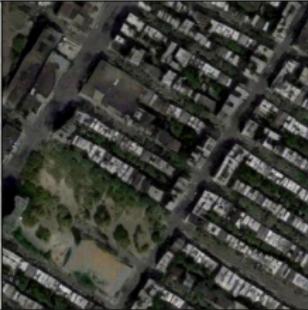
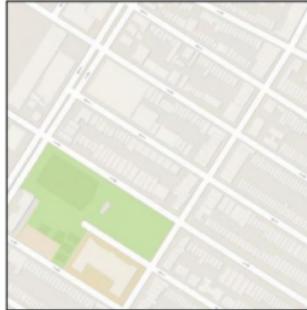
this white and yellow flower
have thin white petals and a
round yellow stamen



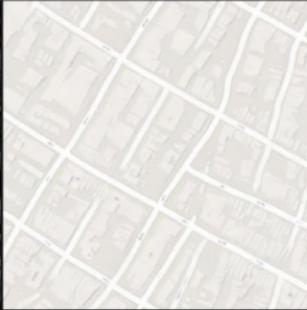
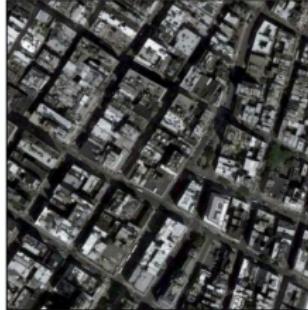


Pix2Pix

Map to aerial photo



Aerial photo to map



input

output

Zebras  Horses



Consideraciones prácticas

- ¿Cómo evaluar los resultados?
- ¿Cómo comparar arquitecturas?
- Mode collapse

Conclusión

- Campo de investigación en auge
- Interesantes aplicaciones en diversos ámbitos
- Difícil entrenamiento
- Difícil evaluación
- Consumo de grandes cantidades de recursos computacionales
- ¡Aún quedan muchas cosas por descubrir!

Referencias principales

-  I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. Generative adversarial nets. In *Advances in neural information processing systems*, pages 2672–2680, 2014.
-  A. Radford, L. Metz, and S. Chintala. Unsupervised representation learning with deep convolutional generative adversarial networks. *arXiv preprint arXiv:1511.06434*, 2015.
-  I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.

Gracias por su atención