

Redes Generativas Antagónicas

Antón Makarov Samusev

Universidad Complutense de Madrid

Universidad Politécnica de Madrid

amakarov@ucm.es

25 de septiembre de 2019

1 Redes Generativas Antagónicas

2 Generación de arte

- DCGAN
- Metodología
- Resultados
- Recursos y rendimiento

3 Arquitecturas basadas en GANs

4 Consideraciones prácticas

5 Conclusión

6 Referencias principales

Descripción del problema

- Goodfellow et. al. 2014

Descripción del problema

- Goodfellow et. al. 2014
- Aprendizaje no supervisado

Descripción del problema

- Goodfellow et. al. 2014
- Aprendizaje no supervisado
- Describir la distribución que siguen los datos

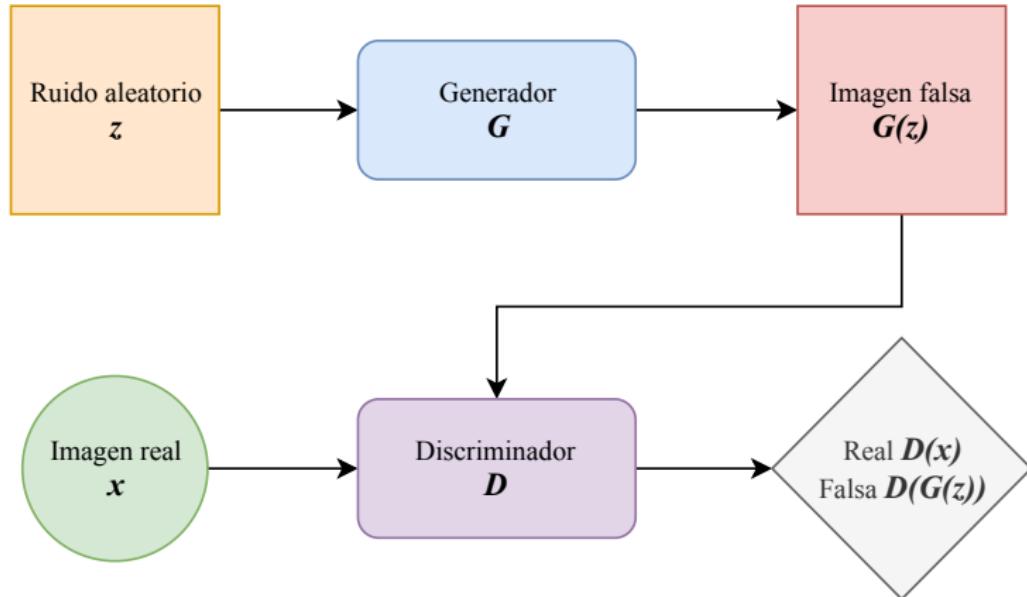
Descripción del problema

- Goodfellow et. al. 2014
- Aprendizaje no supervisado
- Describir la distribución que siguen los datos
- Generar muestras a partir de dicha distribución

Descripción del problema

- Goodfellow et. al. 2014
- Aprendizaje no supervisado
- Describir la distribución que siguen los datos
- Generar muestras a partir de dicha distribución
- Mediante redes neuronales que compiten entre sí

Idea conceptual



Aspectos teóricos

$$\min_G \max_D V(G, D) = \mathbb{E}_{x \sim p_d(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))].$$

Deep Convolutional Generative Adversarial Network

- Discriminador: Convolución con stride
- Generador: Convolución fraccional con stride
- No utilizar capas totalmente conectadas
- Generador: ReLU + tanh
- Discriminador: LeakyReLU + sigmoide
- BatchNorm
- Inicialización gaussiana

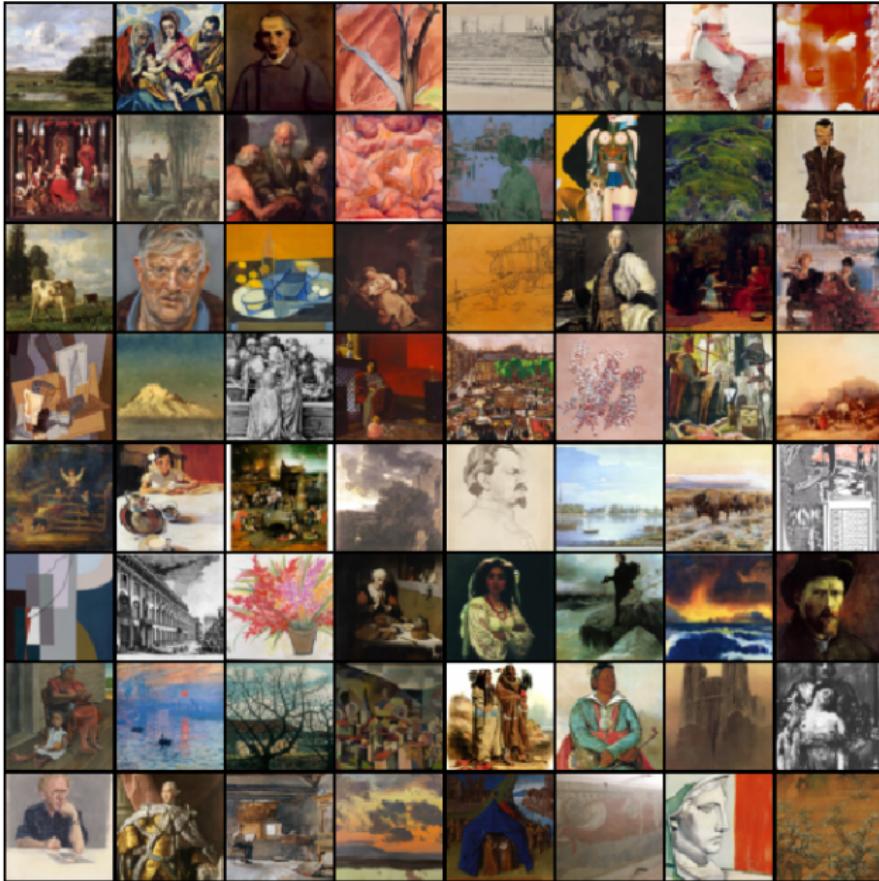
Deep Convolutional Generative Adversarial Network

- Discriminador: Convolución con stride
- Generador: Convolución fraccional con stride
- No utilizar capas totalmente conectadas
- Generador: ReLU + tanh
- Discriminador: LeakyReLU + sigmoide
- BatchNorm
- Inicialización gaussiana
- One sided label smoothing

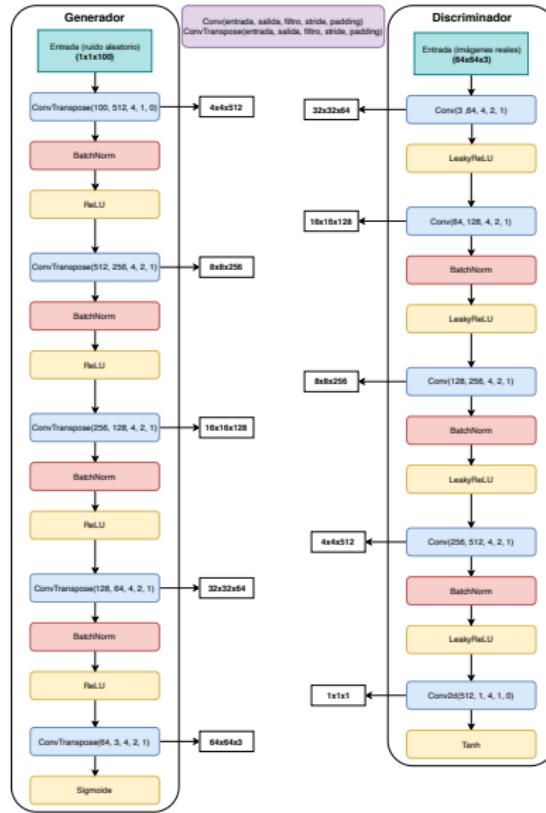
Obtención y pre-procesado

- Conjunto de datos obtenido de una competición de Kaggle
- Más de 100000 imágenes \approx 50 GB
- Algunas imágenes corruptas
- Escalado de tamaños y proporciones
- Normalización
- Carga como tensores

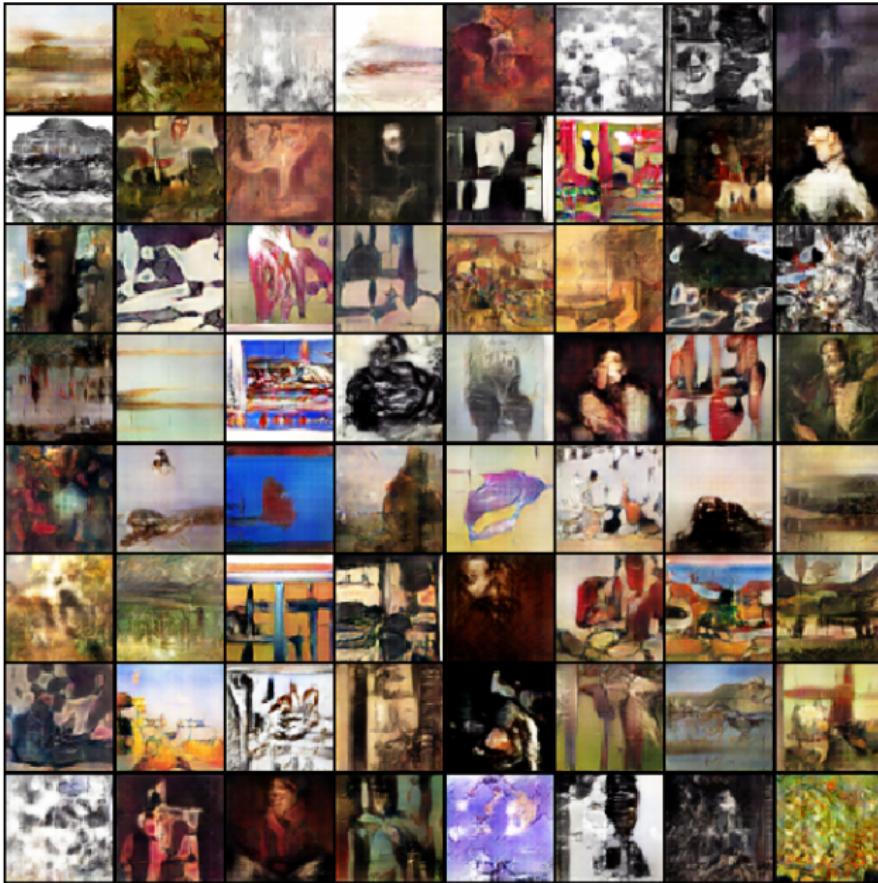
Real Images

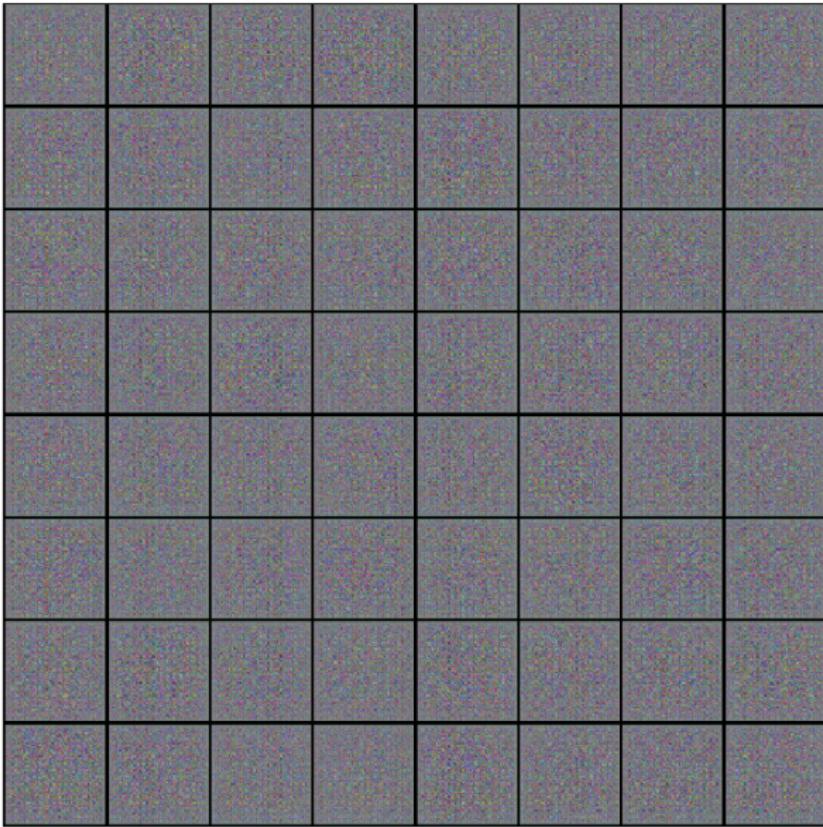


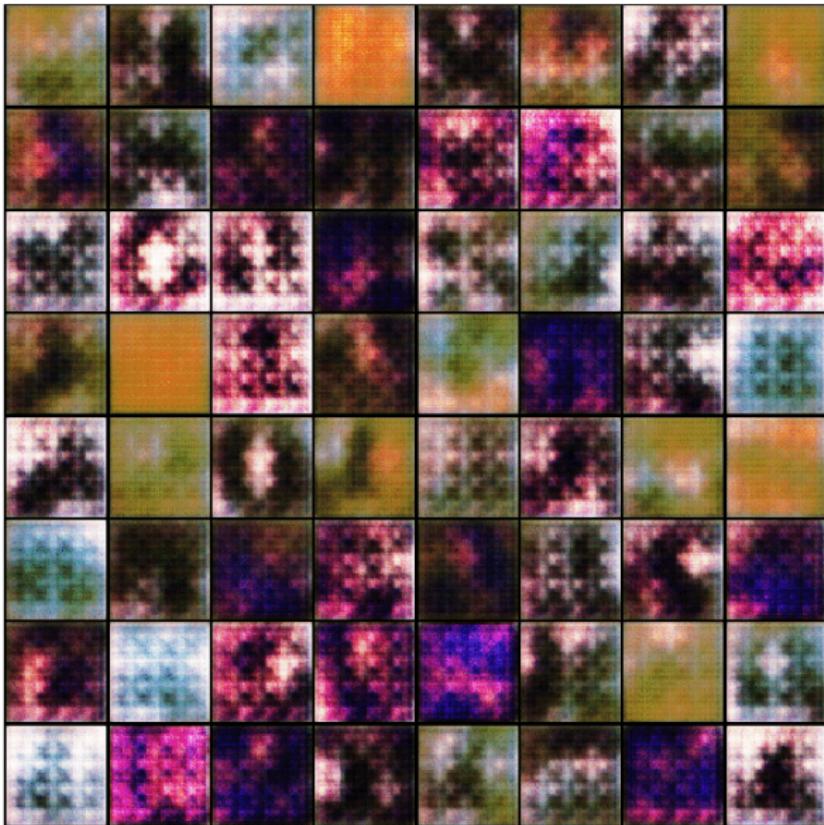
Arquitectura

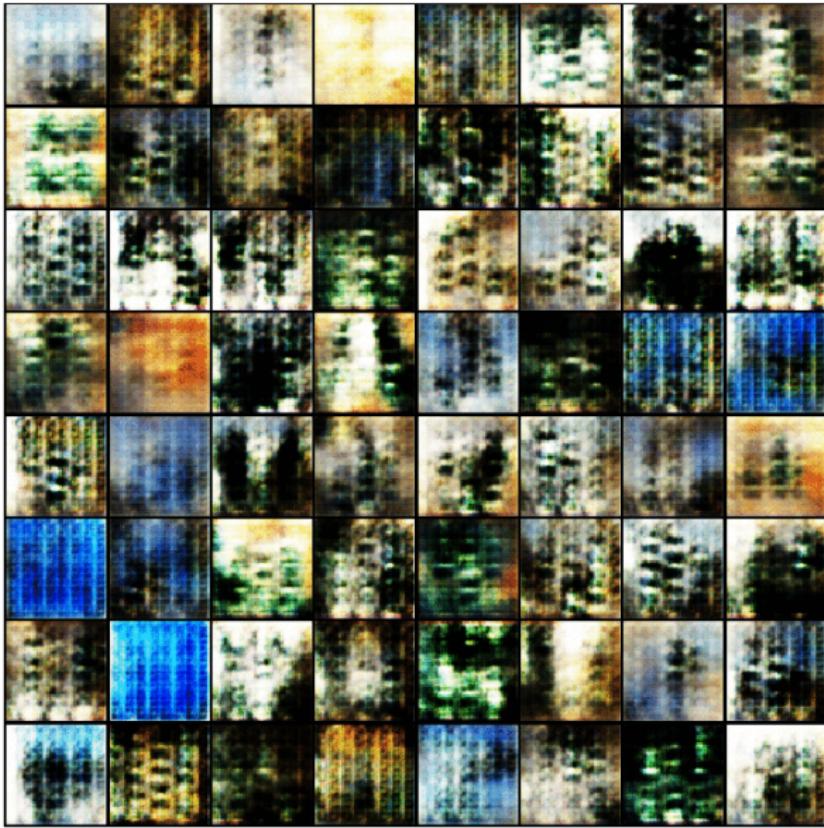


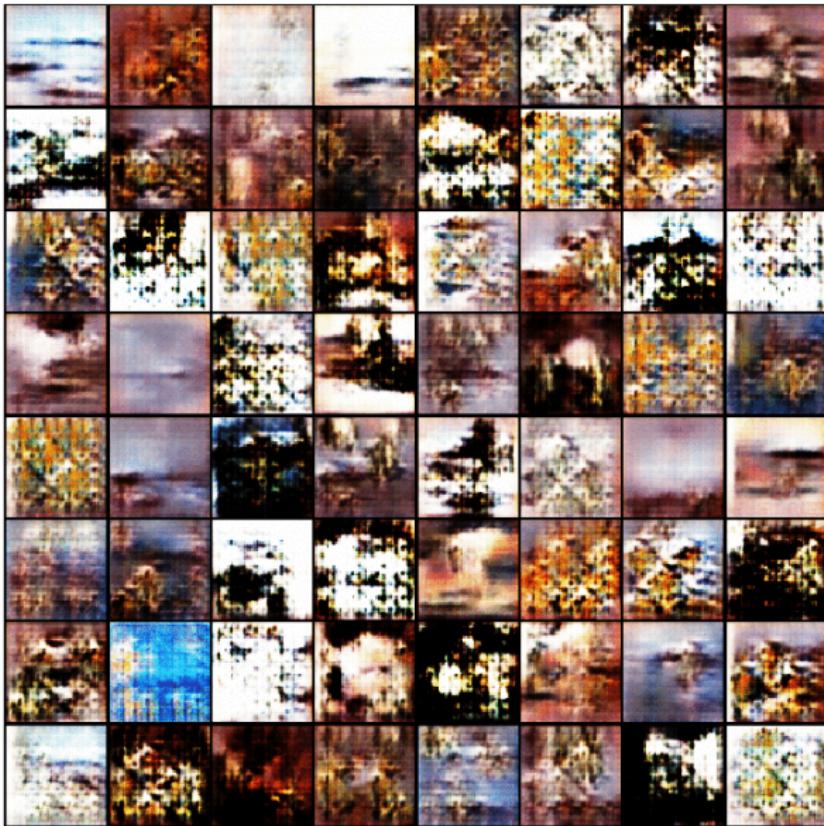
Fake Images

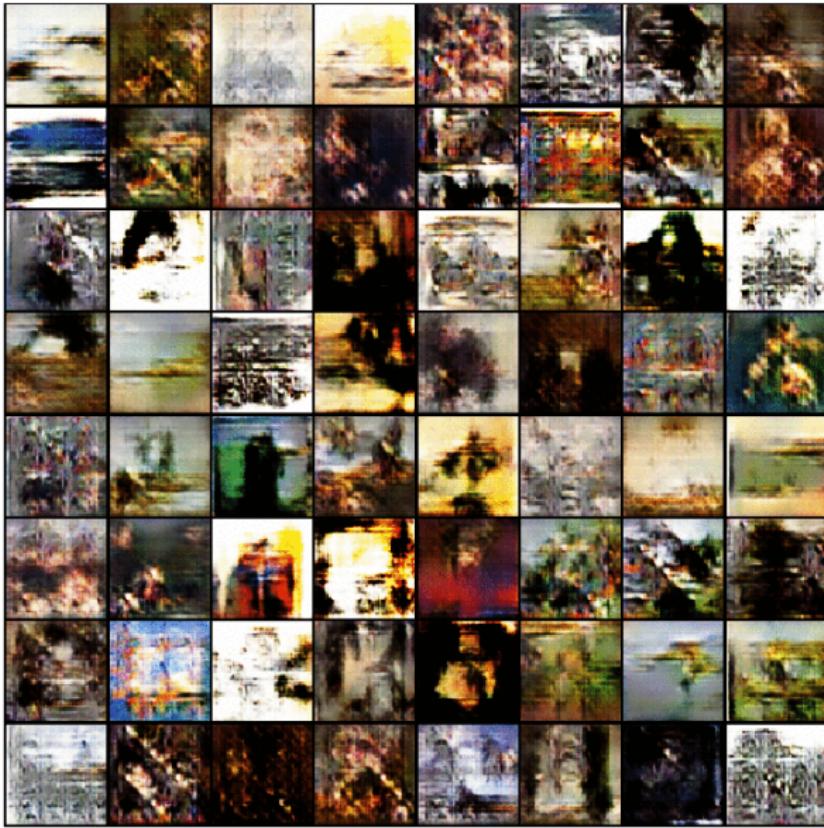


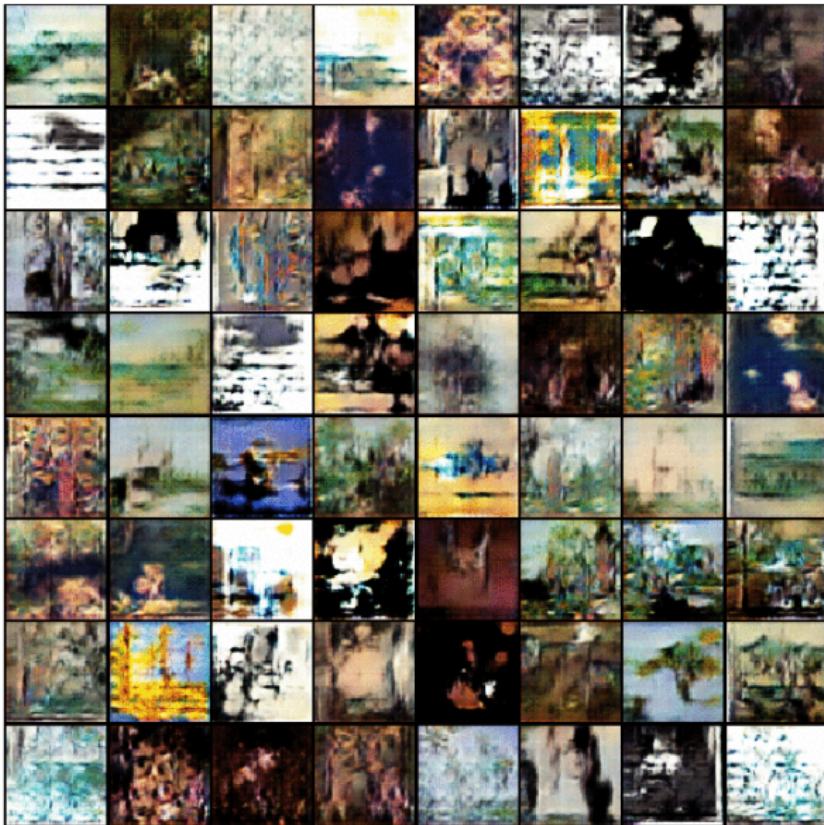




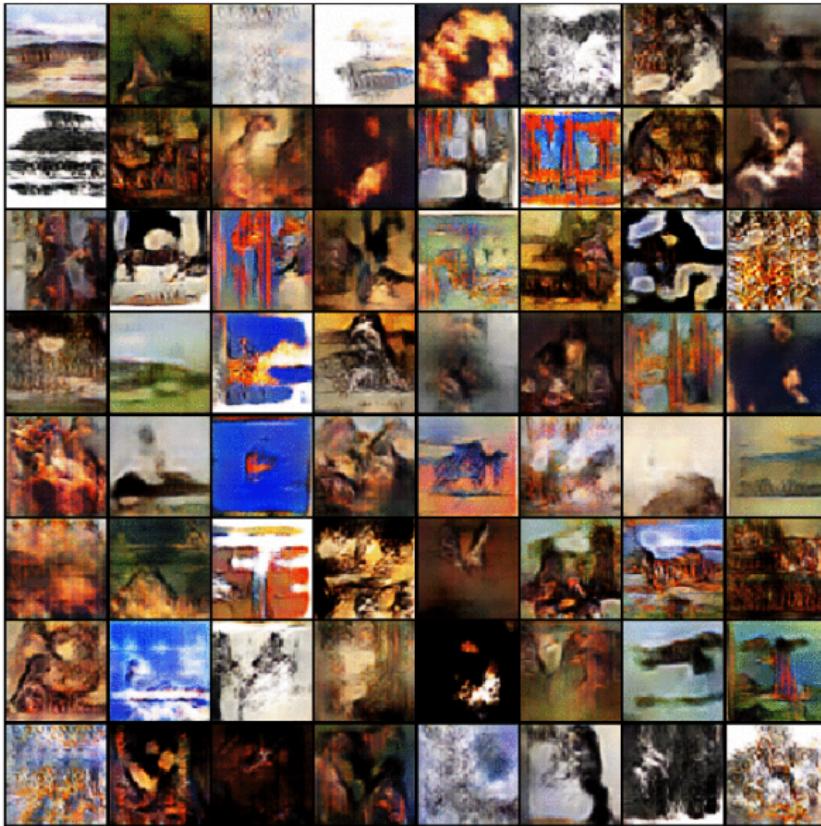


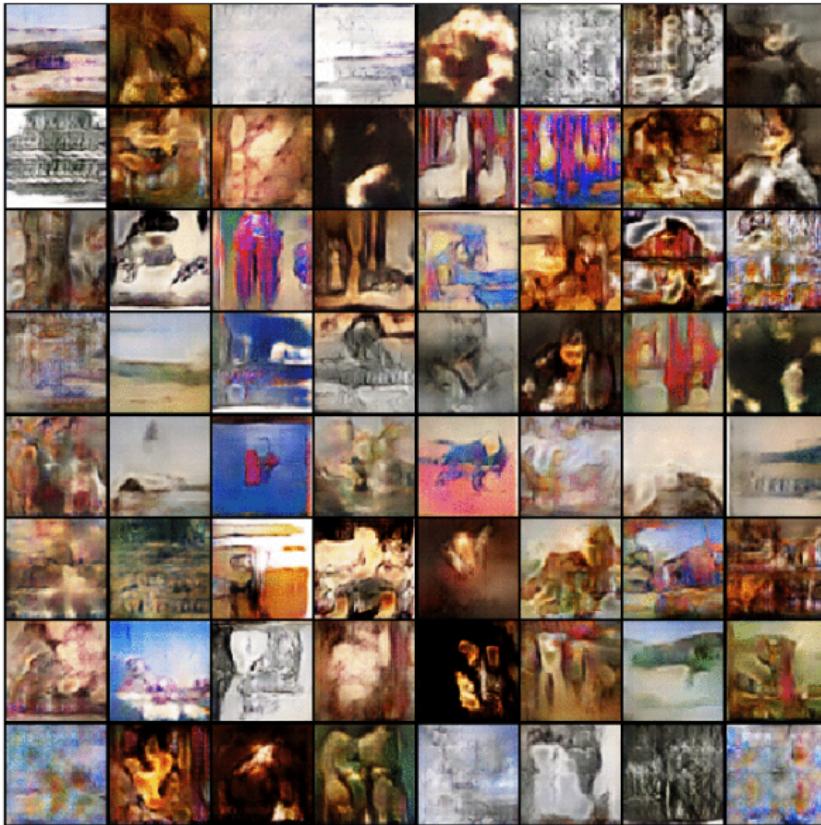


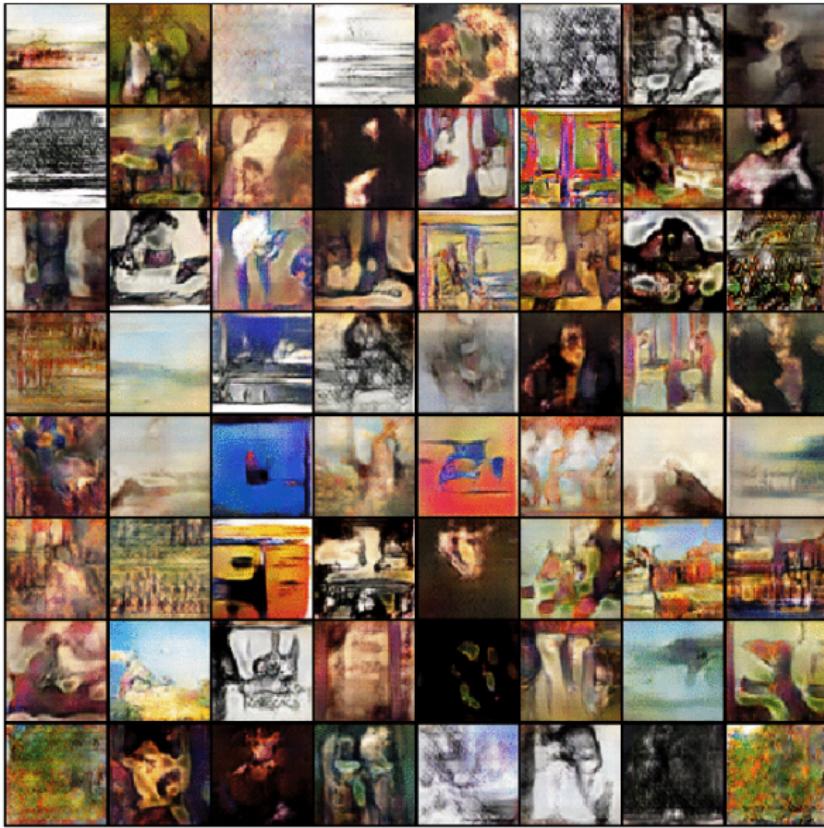


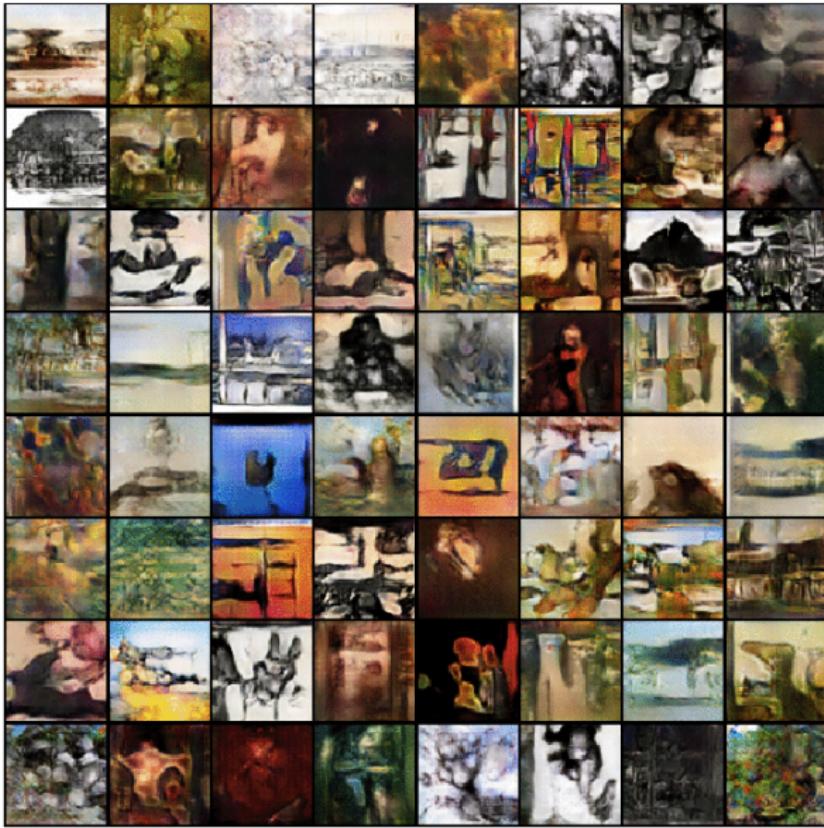


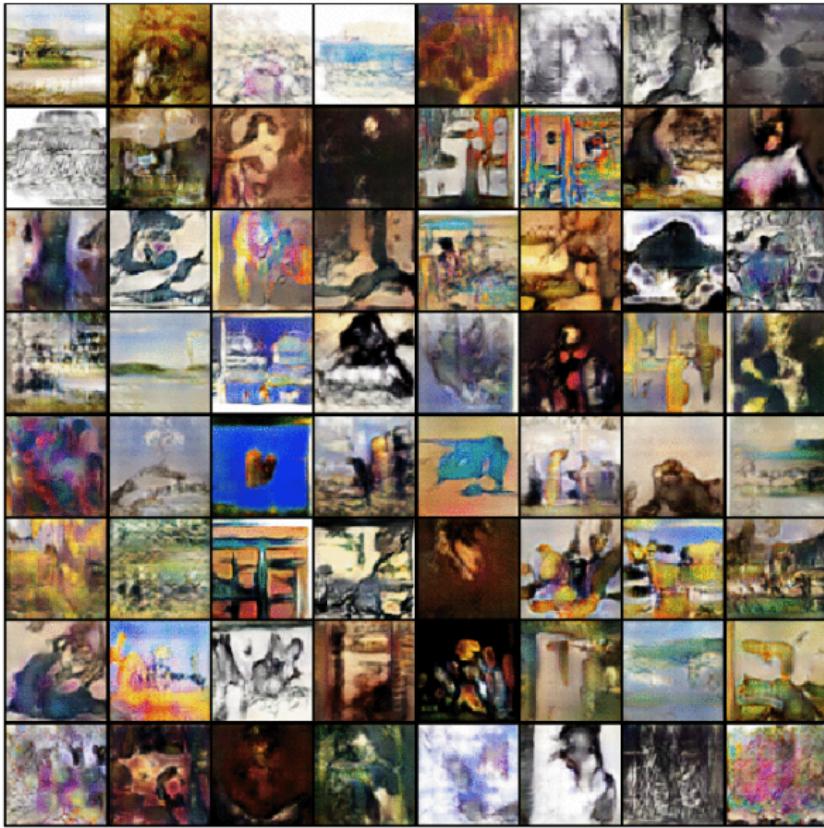


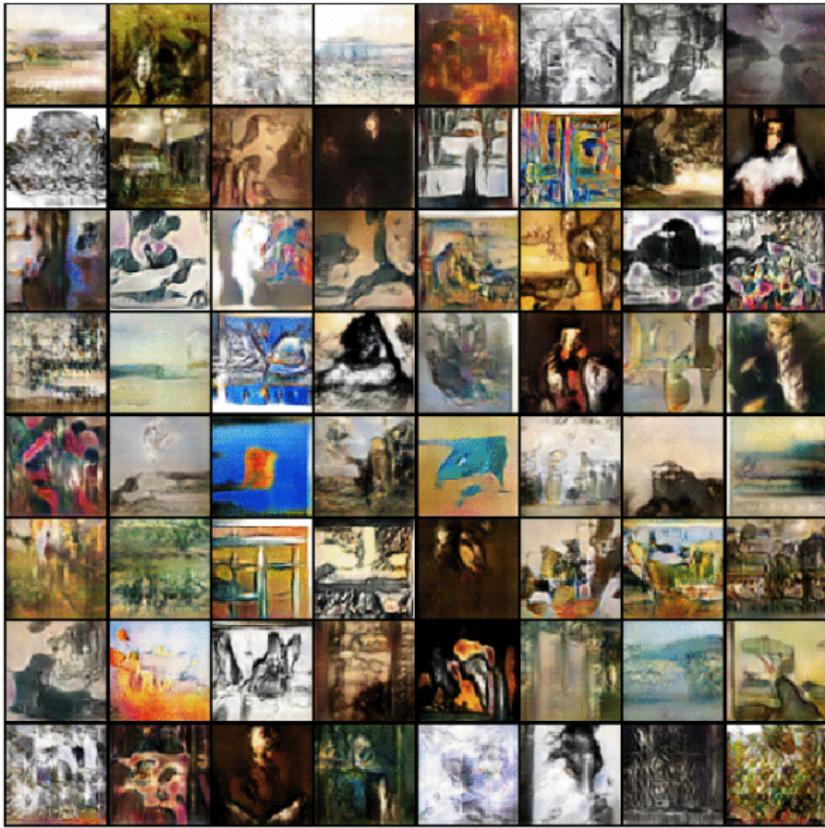


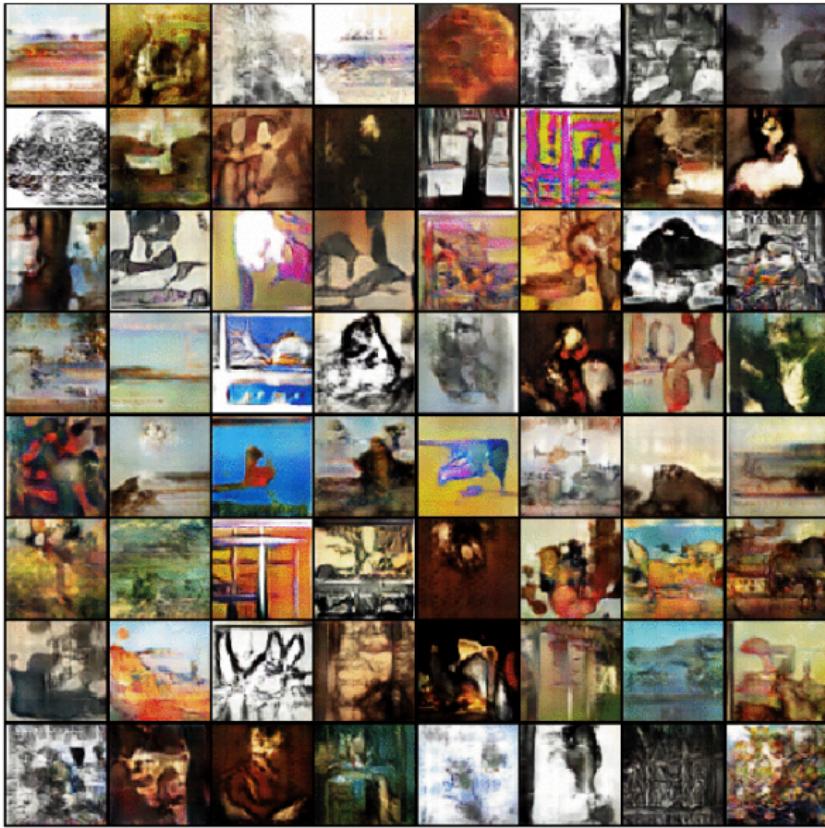


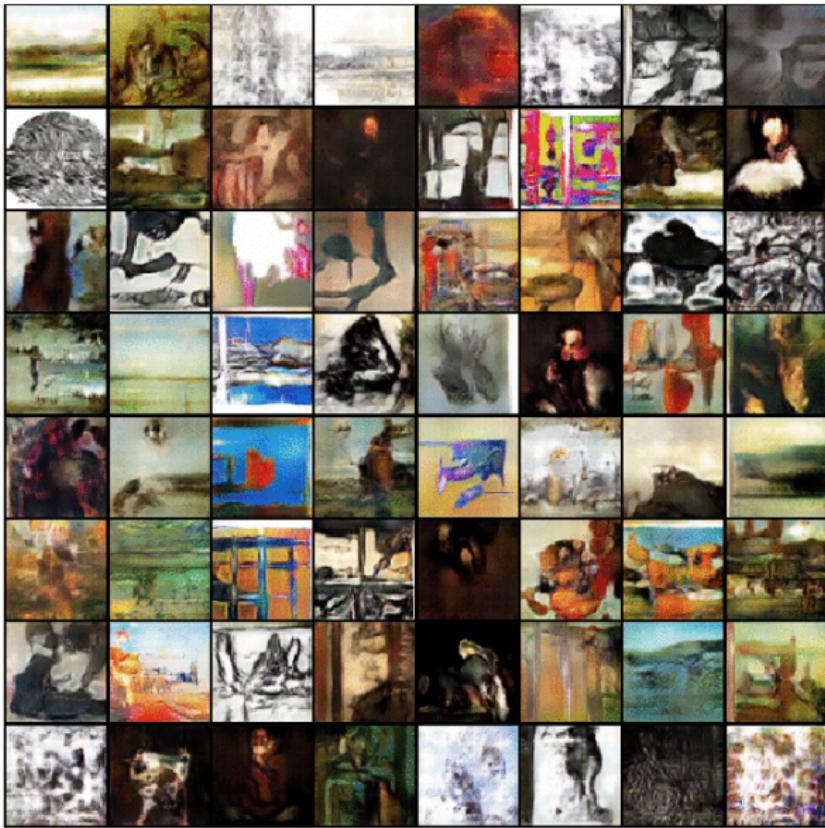


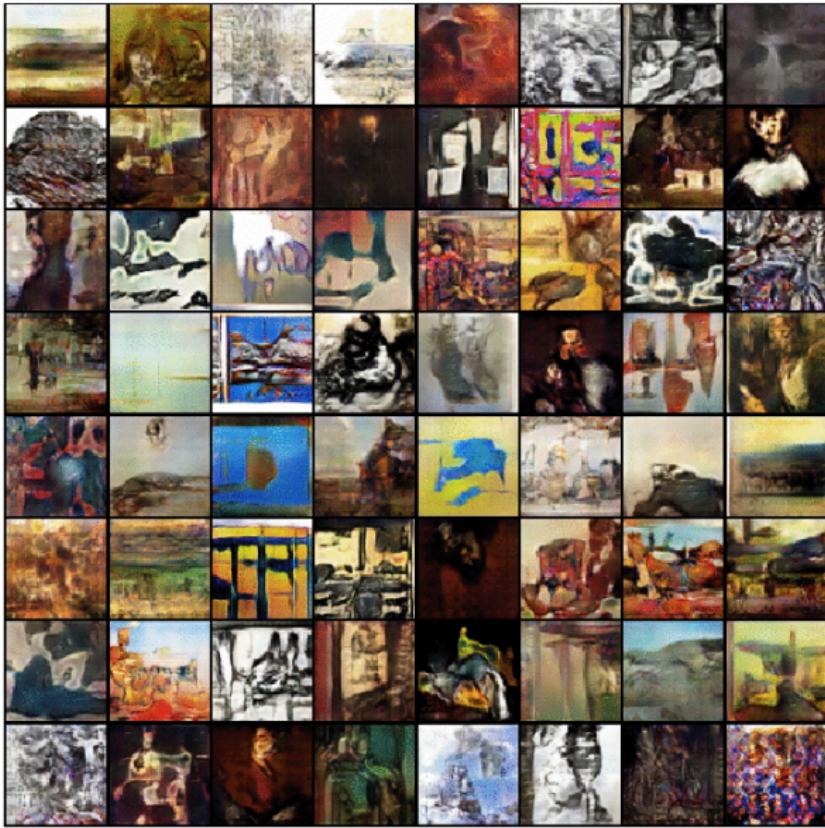


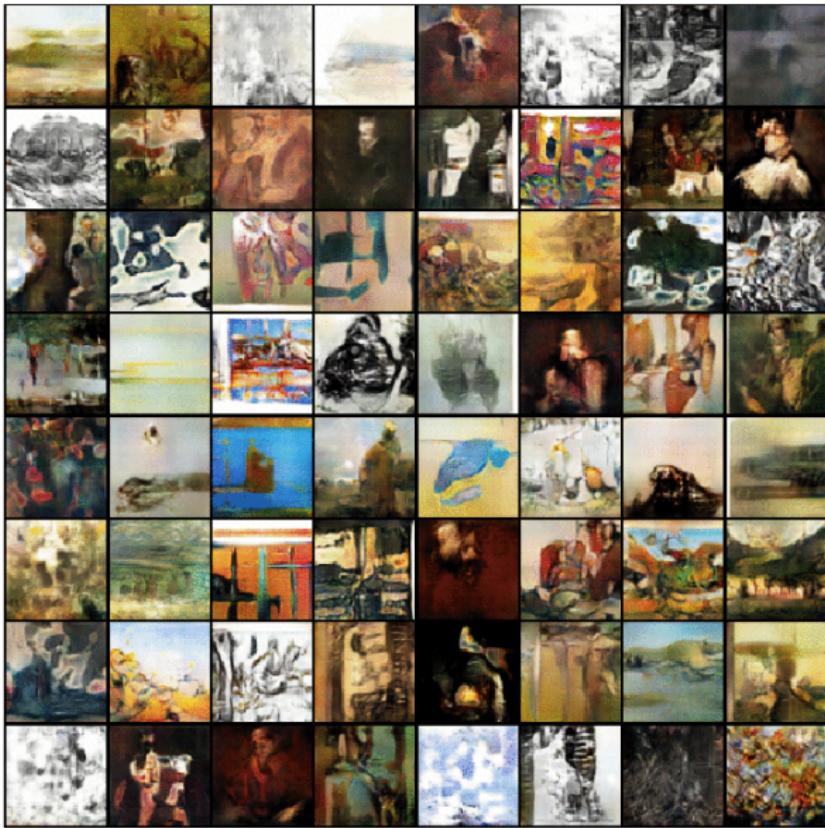












Recursos y rendimiento

- Imprescindible GPU para el entrenamiento
- 24 horas para 30 épocas
- en PC normal, 20 veces más lento

Arquitecturas basadas en GANs



Figura: Ian Goodfellow. *4.5 years of GAN progress on face generation.*

Consideraciones prácticas

- ¿Cómo evaluar los resultados?
- ¿Cómo comparar arquitecturas?
- Mode collapse

Conclusión

- Campo de investigación en auge
-

Referencias principales

-  I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. Generative adversarial nets. In *Advances in neural information processing systems*, pages 2672–2680, 2014.
-  A. Radford, L. Metz, and S. Chintala. Unsupervised representation learning with deep convolutional generative adversarial networks. *arXiv preprint arXiv:1511.06434*, 2015.
-  I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.

Gracias por su atención