

UNIVERSIDAD COMPLUTENSE DE MADRID
FACULTAD DE CIENCIAS MATEMÁTICAS

UNIVERSIDAD POLITÉCNICA DE MADRID
ESCUELA TÉCNICA SUPERIOR DE INGENIEROS DE
TELECOMUNICACIÓN

MÁSTER EN TRATAMIENTO ESTADÍSTICO
COMPUTACIONAL DE LA INFORMACIÓN



TRABAJO DE FIN DE MÁSTER

Redes Generativas Antagónicas

Antón Makarov Samusev

Director

Francisco Javier Yáñez Gestoso

Madrid, 2019

Resumen

Resumen

Abstract

Abstract

Índice general

1. Introducción	7
2. Preliminares	8
2.1. Conceptos básicos	8
2.2. Redes neuronales	8
2.2.1. Aprendizaje profundo	8
2.2.2. Redes neuronales convolucionales	8
3. Redes generativas antagónicas	9
3.1. Idea general	9
3.2. Aspectos teóricos	9
3.3. Otros modelos generativos	10
4. Generación de arte	11
4.1. DCGAN	11
4.2. Resultados	11
5. Conclusión	13
Bibliografía	14

Capítulo 1

Introducción

[3], [1], [4], [2]

Capítulo 2

Preliminares

2.1. Conceptos básicos

Definición 1 (Divergencia de Kullback-Leibler). *hola*

Definición 2 (Divergencia de Jensen-Shannon). *Hola*

2.2. Redes neuronales

2.2.1. Aprendizaje profundo

2.2.2. Redes neuronales convolucionales

Capítulo 3

Redes generativas antagónicas

En este capítulo describiremos las ideas principales, tanto teóricas como prácticas de las redes generativas antagónicas, generative adversarial networks o GANs en inglés. Fueron propuestas por primera vez por Ian Goodfellow en 2014 [3], mezclando conceptos de aprendizaje automático no supervisado, supervisado y teoría de juegos. Desde entonces han suscitado una actividad investigadora muy importante.

3.1. Idea general

El objetivo de las GANs es generar muestras de una distribución, cosa que a priori no parece complicado, existen métodos para generar muestras de variables aleatorias conocidas como por ejemplo la transformada inversa. Sin embargo, supongamos que queremos generar muestras de fotos de perros. Tenemos la seguridad de que la distribución es extremadamente compleja de describir, dado que hay perros de distintos colores, tamaños, razas, etc.

La idea fundamental de las GANs es poner dos redes neuronales a competir entre sí. Una red, llamada generadora (G), está dedicada a obtener imágenes a partir de ruido, mientras que otra, llamada discriminadora (D), trata de averiguar si la imagen es real o ficticia. Es frecuente ilustrar esta idea mediante la analogía de falsificadores de billetes que tratan de engañar a la policía. Los falsificadores empiezan dibujando billetes que no tienen nada que ver con los reales, intentando utilizarlos para pagar, momento en el que son atrapados por la policía. Los falsificadores por tanto se dan cuenta de que están dibujando mal y modifican su técnica, de manera que a lo largo del tiempo aprenden a burlar a la policía, que no es capaz de distinguir billetes reales de falsos. Una representación esquemática se puede ver en la Figura (3.1)

El algoritmo genérico para el entrenamiento de este tipo de redes se describe en el Algoritmo 1.

3.2. Aspectos teóricos

Veamos algunos de los resultados teóricos más relevantes:




Figura 3.1: Diagrama conceptual de las redes generativas antagónicas.

Algoritmo 1: Entrenamiento de una red generativa antagónica genérica.

```

1 for  $e$  in epochs do
2   for  $k$  in batches do
3     Tomar muestra real de imágenes reales;
4      $\text{clasreal} = D(\text{real})$ ;
5     Tomar muestra de ruido aleatorio noise;
6      $\text{fake} = G(\text{noise})$ ;
7      $\text{clasfake} = D(G(\text{noise}))$ 
8   end
9 end

```

Teorema 1. Para un generador G fijo, el discriminador D óptimo es:

$$D_G^*(x) = \frac{p_{\text{datos}}(x)}{p_{\text{datos}}(x) + p_g(x)} \quad (3.1)$$

Demostración. El discriminador busca maximizar su función de utilidad, dada por $V(G, D)$

$$\begin{aligned}
 V(G, D) &= \int_x p_{\text{datos}}(x) \log(D(x)) dx + \int_z p_z(z) \log(1 - D(g(z))) dz \\
 &= \int_x p_{\text{datos}}(x) \log(D(x)) + p_g(x) \log(1 - D(x)) dx
 \end{aligned} \quad (3.2)$$

□

3.3. Otros modelos generativos

Variational autoencoders, noise contrastive estimation etc.

Capítulo 4

Generación de arte

4.1. DCGAN

4.2. Resultados




Figura 4.1: Arquitectura de las redes.

Capítulo 5

Conclusión

Bibliografía

- [1] I. Goodfellow. Nips 2016 tutorial: Generative adversarial networks. *arXiv preprint arXiv:1701.00160*, 2016.
- [2] I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [3] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. Generative adversarial nets. In *Advances in neural information processing systems*, pages 2672–2680, 2014.
- [4] A. Radford, L. Metz, and S. Chintala. Unsupervised representation learning with deep convolutional generative adversarial networks. *arXiv preprint arXiv:1511.06434*, 2015.